



UNIVERSIDADE ESTADUAL DE CAMPINAS  
FACULDADE DE ENGENHARIA MECÂNICA E  
INSTITUTO DE GEOCIÊNCIAS

**Modelamento de propriedades geométricas e  
petrofísicas e Classificação Automática de reservatório em  
um reservatório carbonático naturalmente fraturado na  
Bacia de Campos, Brasil.**

Orientador: Prof. Dr. Alexandre Campana Vidal

Autor: João Fernando Sampaio Ralha

**Campinas**

**2019**

# Sumário

Abstract	3
Índice de Figuras	4
Índice de Tabelas	7
1. Introdução	9
2. CONTEXTO GEOLÓGICO	11
2.1. BACIA DE CAMPOS	11
2.2. GRUPO MACAÉ	12
2.3. CAMPO B	13
3. METODOLOGIA	14
3.1. Análise e apresentação de base de dados disponível	14
3.2. Processamento de atributos sísmicos para realce de descontinuidades.	20
3.3. Estabelecimento do modelo estrutural.	26
3.4. Definição de Camadas e <i>Upscaling</i> de Logs de Poços	28
3.5. Modelamento de Propriedades	31
3.6. Classificação de Reservatório e Cálculos de Volume de Hidrocarbonetos.	33
3.6.1. Valores de cortes baseados em análise estatística simples de propriedades.	35
3.6.2. Clusterização K-Means de células.	35
3.6.3. Classificação por modelo de mistura gaussiana.	39
4. RESULTADOS E DISCUSSÃO	40
4.1. Processamento Sísmico e Descontinuidades	40
4.2. Upscaling e Modelamento de Propriedades	47
4.3. Classificação de Reservatório	59
4.4. Cálculos de Volume	66
5. CONCLUSÕES	70
6. REFERÊNCIAS BIBLIOGRÁFICAS	71

## **Abstract**

# Índice de Figuras

Figura 1 - Localização da Bacia de Campos (modificado de Rangel e Martins, 1998) ...	11
Figura 2 - Carta estratigráfica da Bacia de Campos simplificada. (Modificada de Guardado et al., 2000, e parcialmente atualizada após Winter et al., 2007, in Melani, 2015). ....	12
Figura 3 - Extensões em superfície do reservatório e do volume sísmico no domínio da profundidade. Números ao redor da extensão do volume sísmico correspondem à crosslines e inlines. ....	15
Figura 4 - Horizontes carregados - De cima para baixo: Formação Outeiro, Formação Imbetiba, Formação Quissamã e Grupo Lagoa Feia. Cubo no entorno representa os limites do volume sísmico com profundidades de 1798m até 3076m ....	16
Figura 5 - Localização dos 47 poços estudados, ícones representam as coordenadas em que os poços têm sua maior profundidade, não sua localização em superfície. ....	16
Figura 6 - Pickett Plot utilizado na determinação do fator de cimentação ( $m = 1,77$ ). De Melani et al. 2015. ....	19
Figura 7 - Fluxo de trabalho para geração de volumes de ant-tracking. ....	21
Figura 8 - Visualização do fluxo de trabalho utilizado identificando uma descontinuidade. ....	24
Figura 9 - Exemplo de fluxo de trabalho para modelamento estrutural. Os dados de interpretações de estruturas e horizontes são inicialmente carregados (a) para então horizontes serem modificados de acordo com sua relação com estruturas que os interceptam (b) e finalmente é gerado um modelo volumétrico de zonas com base nas superfícies modeladas (c). Alterado de Schlumberger (2015). ....	26
Figura 10 - Horizonte do topo Quissamã. (a) Mostra o horizonte originalmente carregado. (b) Mostra o horizonte modificado pelas interseções com estruturas. Áreas em azul representam superfícies de feições estruturais. ....	28
Figura 11 – (a) Modelo volumétrico de zonas com camadas definidas e (b) Zona do Quissamã entre os horizontes do Quissamã e do Lagoa Feia isolado do resto do modelo. ....	29
Figura 12 – Diagrama do funcionamento do algoritmo de upscaling de dados de poço para a escala do modelo. Para cada célula do grid colunar é atribuído um valor para cada log correspondente ao valor médio do log no espaço amostral correspondente à célula. ....	30
Figura 13 - Grid colunares de porosidade efetiva (PHIE) cortados para a região entre o topo do Quissamã (superfície em roxo) e o contato óleo-água (superfície em preto)...	30
Figura 14 - Ilustração da obtenção de valores residuais para métodos de Krigagem com Deriva Externa (aqui denominado como regression-kriging). De: Hengl (2009). ...	32
Figura 15 - Atributo de Ant-Tracking no crossline 1744. Refletor entre 2200m e 2400m de profundidade corresponde ao horizonte do topo do Quissamã. Refletor entre 2600m e 2800m de profundidade corresponde ao horizonte do topo do Lagoa Feia. Nota-se a ocorrência de forma disseminada de descontinuidades detectadas pelo fluxo de trabalho definido. ....	41
Figura 16 - Atributo de Ant-Tracking nos cortes em profundidade de 2300 e 2500m. 2300m sendo a profundidade aproximada do topo do Quissamã e 2500m a profundidade aproximada do contato óleo-água. ....	42
Figura 17 - Distribuição de descontinuidades para todas as descontinuidades. Estruturas predominantemente Leste-Oeste com mergulhos para Norte e Sul. ....	42

<b>Figura 18 - Distribuição de descontinuidades com mais de 200m de extensão em qualquer direção. Nota-se a manutenção da tendência estrutural observada para o conjunto de todas as descontinuidades.</b>	<b>43</b>
<b>Figura 19 - Variação de Ant-Tracking com Latitude. Não se observa tendência clara na distribuição entre as duas variáveis. Cada ponto no gráfico corresponde à uma célula no modelo. Consideradas apenas células dentro do reservatório (Entre Quissamã e contato óleo-água).</b>	<b>44</b>
<b>Figura 20 - Delimitação de Zonas Norte e Sul do reservatório, cada uma com 234.109 células. Fronteira entre as zonas encontra-se deslocada para o sul devido à maior espessura do reservatório na Zona Sul. Cada ponto no gráfico corresponde à uma célula no modelo. Pontos plotados independentemente de sua posição vertical. Consideradas apenas células dentro do reservatório (Entre Quissamã e contato óleo-água).</b>	<b>45</b>
<b>Figura 21 - Distribuição no espaço para os pontos de altos valores de Ant-Tracking. - 0.91 corresponde ao valor médio de Ant-Tracking no reservatório adicionado ao valor do desvio padrão de Ant-Tracking no reservatório, -0.78 representa o valor médio somado a três vezes o desvio padrão. Nota-se a maior frequência com que estes pontos ocorrem na zona sul em relação à zona norte. Cada ponto no gráfico corresponde à uma célula no modelo. Pontos plotados independentemente de sua posição vertical. Consideradas apenas células dentro do reservatório (Entre Quissamã e contato óleo-água).</b>	<b>45</b>
<b>Figura 22 - Porcentagem de células localizadas na Zona Norte ou Sul para cada valor mínimo de Ant-Tracking (Limiar). Nota-se que para Ant-Tracking de -1,0 os valores se distribuem igualmente entre as duas zonas, refletindo a separação das duas zonas pela Latitude mediana do reservatório. Para valores entre -0;8 e 0, valores que se correlacionam com elevadas intensidades de fraturamento, de 60% a 75% dos valores encontram-se na Zona Sul. Para os poucos (n = 151) valores positivos de Ant-Tracking, estes concentram-se fortemente na Zona Norte. Assim indicando que as descontinuidades ocorrem de maneira mais disseminada pela Zona Sul enquanto concentram-se em uma área de alta descontinuidade na Zona Norte.</b>	<b>47</b>
<b>Figura 23 - Distribuição de dados de Saturação de Água. Dados após upscaling honram bem os dados de poço. Modelagem por KDE tem como efeito a possível superestimação de valores medianos de saturação e suprimindo valores de baixa saturação. Efeitos do modelamento indicam que os cálculos de volume possam acabar subestimando o volume de hidrocarbonetos HCPV.</b>	<b>48</b>
<b>Figura 24 - Distribuição de dados de Porosidade Efetiva. Dados de upscaling e modelados por GRFS honram de maneira satisfatória seus dados de input. Resultando num modelo confiável para a distribuição de valores de porosidade ao longo do reservatório.</b>	<b>49</b>
<b>Figura 25 – Distribuição de dados de raio gama. Embora o algoritmo de GRFS tenha honrado de maneira satisfatória a distribuição dos dados após upscaling, o método de upscaling acaba por subestimar valores de baixo GR entre 30 e 40 gAPI.</b>	<b>49</b>
<b>Figura 26 – Distribuição de dados de densidade. Assim como para dados de porosidade efetiva, tanto o algoritmo de GRFS quanto o método de upscaling honram seus dados de input.</b>	<b>50</b>
<b>Figura 27 – Distribuição de dados de resistividade. Assim como para os dados de raio gama, o algoritmo de GRFS honra de maneira satisfatória os dados de upscaling, enquanto o método de upscaling acaba por subestimar valores intermediários entre 5 e 10 ohm.m</b>	<b>50</b>

Figura 28 – Modelo de saturação de água (SW). Valores distribuem-se de maneira similar para diferentes níveis de saturação de água. Algoritmo de KDE resulta em transições de valores suavizadas. Nota-se os maiores valores de saturação próximos ao topo e base do reservatório, evidenciando as regiões de fronteira do reservatório, assim como a presença de uma região na porção sudoeste do reservatório com valores muito baixos de saturação. ....	53
Figura 29 - Modelo de porosidade efetiva (PHIE). Valores distribuídos em camadas horizontais contendo maiores valores. Observa-se associação entre maiores valores de porosidade nos mesmos locais onde ocorrem menores valores de saturação de água (SW). ....	54
Figura 30 - Modelo de raio gama (GR). Observa-se dependência entre os valores modelados e profundidade, com valores próximos ao topo da Formação Quissamã apresentando um aumento nos valores de raio gama observados. ....	55
Figura 31 – Modelo de resistividade (ILD). Observa-se predominância de valores baixos. A ocorrência de picos com valores bastante elevados na região sudoeste do modelo explica os altos valores de CV observados na Tabela 8. ....	56
Figura 32 – Modelo de Densidade (RHOB). Valores aproximadamente constantes em torno da média de aproximadamente 2400g/cm <sup>3</sup> explicam baixos valores de CV observados na Tabela 8. Ao mesmo tempo, raras variações são observadas na região sudoeste, com quedas nos valores de Densidade associadas a valores de alta porosidade, alta resistividade e baixa saturação de água. ....	57
Figura 33 – Distribuições par a par das propriedades modeladas. Histogramas de distribuição das propriedades em casos em que a propriedade é comparada a ela mesma. Valores intermediários de correlação entre SW-PHIE e SW-RHOB observados na Tabela 9 podem ser visualizados. Nota-se ainda a distribuição concentrada em baixos valores observada para a propriedade de resistividade (ILD). ....	58
Figura 34 - Distribuição de valores modelados de saturação de água (SW), porosidade efetiva (PHIE) e raio gama (GR). Observam-se os baixos valores de correção de GR com as demais propriedades detalhadas na Tabela 9. ....	59
Figura 35 – Matriz de Distâncias e respostas à cada variável do algoritmo de mapas auto organizáveis (SOM). Observa-se a relação entre altas respostas de porosidade e resistividade com baixas respostas de saturação de água e densidade. ....	60
Figura 36 – Valores para os índices de silhueta e Davies-Bouldin computados para diferentes valores de K no algoritmo K-Means. O valor máximo para índice de silhueta e mínimo para Davies-Bouldin no valor de 3 classes indica provável separação dos dados em 3 diferente classes. ....	61
Figura 37 – Classificações da matriz de distâncias. Valores entre 0 e 1 para o mapa de probabilidades de GMM são a probabilidade de cada neurônio pertencer a classe 0...61	61
Figura 38 – Mapas de distribuição das classificações para K-Means e GMM e propriedades de porosidade efetiva e saturação de água para profundidade de 2392m. Linha laranja indica as seções transversais da Figura 39. ....	64
Figura 39 - Seções transversais para as distribuições das classificações obtidas de K-Means e GMM. Seções correspondem as linhas indicadas nos mapas da Figura 38. ....	65
Figura 40 – Mapa e seção transversal de distribuição de probabilidades de cada célula pertencer a Classe 0 ou 1 na classificação obtida do método GMM. ....	66

## Índice de Tabelas

Tabela 1 - Profundidades dos horizontes carregados. O horizonte 'OWC' representa o contato óleo-água (Oil Water Contact) enquanto o horizonte 'Água Até' representa as profundidades mais rasas com conteúdo de água dentro do reservatório. ....	15
Tabela 2 - Relação de disponibilidade de logs para cada poço estudado. A coluna de saturação de água diz respeito as 4 curvas determinadas por Melani et al. (2015), visto que, para os poços em que elas estão disponíveis, as 4 curvas encontram-se disponíveis. ....	17
Tabela 3 - Fatores de cimentação e saturação para cada um dos cenários de cálculo de saturação de água. De Melani et al. (2015) .....	18
Tabela 4 - Definição de parâmetros para o atributo de ant-tracking e valores utilizados no processamento do atributo. Os valores tomados para cada parâmetro seguem os valores sugeridos na literatura para reservatórios fraturados. Baseado em Schlumberger (2015).....	25
Tabela 5 - Distribuição dos valores de Ant-Tracking nas diferentes Zonas do volume sísmico. Embora a Zona Sul mostre um valor média de Ant-Tracking superior tanto à Zona Norte quanto a região não reservatório do Quissamã, a diferença observada na média é menor do que o desvio padrão destas medidas. ....	46
Tabela 6 – Número de células por zona com valores de Ant-Tracking superiores a - 0.91. O valor de -0.91 corresponde ao valor médio de Ant-Tracking na região sobre o contato óleo-água dentro da Formação Quissamã adicionado ao desvio padrão do valor de Ant-Tracking nesta mesma região. ....	46
Tabela 7 - Número de células por zona com valores de Ant-Tracking superiores a - 0.78. O valor de -0.78 corresponde ao valor médio de Ant-Tracking na região sobre o contato óleo-água dentro da Formação Quissamã adicionado à três vezes o desvio padrão do valor de Ant-Tracking nesta mesma região. ....	46
Tabela 8 - Valores estatísticos para a distribuição dos valores modelados. CV é o coeficiente de variação. ....	51
Tabela 9 – Valores de correlação entre as propriedades modeladas. Tabela tem valores repetidos omitidos. ....	52
Tabela 10 - Distribuição estatística das propriedades modeladas entre as classes obtidas com o algoritmo de Modelo de Mistura Gaussiana, GMM.....	63
Tabela 11 – Distribuição estatística das propriedades modeladas entre as classes obtidas com o algoritmo de K-Means. ....	63
Tabela 12 – Volumes obtidos para cada classe de acordo com os classificadores de K-Means e GMM. Os valores percentuais indicam a relação entre o volume referido e o obtido para a mesma classe do K-Means. Vb (Bulk Volume) é o volume total das células de cada classe, Vp (Pore Volume) o volume poroso enquanto HCPV (Hydrocarbon Pore Volume) é o volume de hidrocarbonetos. ....	67
Tabela 13 – Relação dos casos de cálculos de volume. Casos que trazem valores de Prop para saturação de água (SW) ou porosidade efetiva (PHIE) utilizam os valores modelados para cada célula para o cálculo. [1] O Caso 3 utiliza o valor constante de 0.581 para saturação de água, valor correspondente ao valor médio no reservatório. [2] O Caso 2 utiliza o valor constante de 0.198 para porosidade efetiva, valor corresponde ao valor médio no reservatório. [3] Valores de N/G de 0 ou 1 para cada célula baseados na classificação em poços de Melani et al. (2015), cada célula possui valor atribuído igual ao ponto mais próximo nos poços classificados. [4] Valores de corte baseados no percentil de 50% para ambas as propriedades. [5] Valores de corte	

baseados no percentil de 75% para ambas as propriedades. [6] Valores de corte baseados no percentil de 90% para ambas as propriedades. ....	67
Tabela 14 – Valores de volumes obtidos para cada caso descrito na Tabela 13. Vb (Bulk Volume) é o volume total das células de cada classe, Vp (Pore Volume) o volume poroso enquanto HCPV (Hydrocarbon Pore Volume) é o volume de hidrocarbonetos e tHCPV é o volume de hidrocarbonetos antes de aplicação das razões N/G. Valores percentuais indicam a variação de cada caso em relação ao Caso 0. Casos 7 e 8 apresentam valores de volume total (Vb) diferentes pois não incluem as células da Classe 0. ....	
	68



## 1. Introdução

Na indústria de exploração em petróleo e gás, o conceito de modelamento de reservatório é entendido como a integração de **diferentes** fontes de dados em **diferentes** resoluções e qualidades com o objetivo de desenvolver uma representação acurada da geologia em subsuperfície. A combinação de conceitos de geoestatística com **maiores** capacidades de processamento e bases de dados cada vez **maiores** inicia assim o processo de técnicas estatísticas sendo utilizadas para a inferência e estimativa de propriedades geológicas (Ringrose & Bentley, 2014a).

Nota-se conjuntamente ao desenvolvimento de novas tecnologias, um aumento constante na capacidade de um único geocientista em prover informações quantitativas e qualitativas sobre a geologia em subsuperfície. Possibilitando a realização de modelos preditivos de alta complexidade (Trabanou et al, 2004). A complexidade de dado processo se mostra na quantidade de variáveis, na variabilidade da resposta a estas variáveis, na qualidade, extensão e resolução dos dados disponíveis bem como na subjetividade associada a interpretações e decisões do operador (Hall, 2013; Anderson & Newrick, 2008).

A construção de modelos geológicos deve ter um objetivo claro desde o seu início, pois as considerações e requerimentos são tão diferentes quanto seus objetivos. Ainda que a maior parte dos modelos somente busque a visualização de inferências sobre a geologia local. O cálculo de modelos para estimativas de volume de reservatório é majoritariamente ligado a propriedades estatisticamente aditivas como saturação de água e porosidade, assim, grids voltados ao cálculo de volumes devem ter extensões claras e bem definidas e não requerem alto nível de detalhamento quanto à sua resolução (Ringrose & Bentley, 2014c).

Em sua maioria, técnicas em modelamento geoestatístico dependem de modelos de natureza gaussiana, mesmo simulações classificadas como bayesianas ainda dependem de modelos gaussianos multivariáveis para ajustes. Modelos geológicos, no entanto, consistem em diversos componentes que não podem ser descritos satisfatoriamente por variáveis aleatórias, distribuições normais e suas probabilidades associadas, fazendo com que o estado da arte em técnicas de modelamento seja indefinido para um grande número de processos (Caers et al., 2010).

Este estudo visa desenvolver modelos de propriedades geométricas e petrofísicas, além de propriedades derivadas de atributos sísmicos, de um reservatório naturalmente fraturado (Chamado aqui de “Campo B”) inserido no intervalo de idade do albio da Bacia de Campos. Possibilitando cálculos de volume e classificação de zonas de interesse no reservatório por meio da inferência de propriedades em zonas inter-poços e métodos computacionais. O Campo B mostra-se como de especial interesse para este estudo por se tratar de um reservatório naturalmente fraturado inserido em uma anticlinal, tornando o controle estrutural um fator de alta relevância na definição das extensões finais do modelo.

O estudo caracteriza-se por uma etapa inicial de processamento de dados de sísmica de reflexão para o realce e identificação automática de feições estruturais no reservatório. Servindo como entrada em uma etapa seguinte de modelamento estrutural onde dados de horizontes são deformados por estas estruturas.

Com um modelo estrutural definido, segue uma etapa de população do modelo com valores oriundos de medidas simples, algoritmos determinísticos (Krigagem com Deriva Externa, KDE) e algoritmos parcialmente baseados em simulações gaussianas (Gaussian Random Function Simulation, GRFS). Obtendo a distribuição espacial das propriedades de poço modeladas.

Para a etapa de classificação de reservatório e cálculos de volume, são utilizadas técnicas computacionais de aprendizado de máquina não supervisionado como Mapas Auto Organizáveis (Self Organizing Maps, SOM), K-Means e Modelos de Mistura Gaussiana (Gaussian Mixture Models, GMM) para a separação de áreas do reservatório de acordo com as propriedades modeladas anteriormente, o fluxo de trabalho realizado para as classificações é adaptado dos métodos utilizados por Kuroda et al. (2011) para classificação de dados de poço.

A base de dados deste estudo inclui horizontes no domínio da profundidade para o topo e base do reservatório além de outras unidades geológicas estratigraficamente próximas, volume 3D de sísmica de reflexão no domínio da profundidade recortado para a área do reservatório e logs de poço com diferentes disponibilidades de logs para 47 poços diferentes interceptando ou próximos ao reservatório, dados todos fornecidos pela Agência Nacional de Petróleo – ANP.

## 2. CONTEXTO GEOLÓGICO

### 2.1 BACIA DE CAMPOS

A Bacia de Campos, localizada no sudeste do Brasil, na costa dos estados do Rio de Janeiro e Espírito Santo (Figura 1), ocupa uma área de 115 mil km<sup>2</sup> desde a linha de costa (Bruhn et al., 1998). Reservatórios de hidrocarbonetos da Bacia de Campos têm como geradoras as rochas do Grupo Lagoa Feia (Bruhn et al., 2003). A Bacia de Campos é considerada a bacia brasileira de maior interesse econômico, com mais de 30 anos de exploração contínua e mais de 1600 poços, compreendendo mais de 75% da produção e das reservas brasileiras de hidrocarbonetos (ANP, 2013).



**Figura 1 - Localização da Bacia de Campos (modificado de Rangel e Martins, 1998)**

Bacia de margem passiva, a Bacia de Campos tem sua evolução relacionada à quebra do Gondwana (Guardado et al. 1989; Dias et al., 1990). Definem-se assim 2 estilos estruturais principais à bacia: (1) falhamentos de blocos relacionados à fase *rift*, compondo *horsts*, *grabens* e *semi-grabens*, envolvendo o embasamento e sedimentos do pré-sal e (2) estruturas geradas pela movimentação de sal, em geral falhas lístricas, afetando sedimentos do pós-sal (Spadini, 1992; Figueiredo & Mohriak, 1984; Guardado et al., 1989; Dias et al., 1990).

Winter et al. (2007) dividem a estratigrafia da Bacia de Campos em Formação Cabiúnas, Grupo Lagoa Feia, Grupo Macaé e Grupo Campos (Figura 2). O Campo B, estudado neste trabalho, encontra-se inserido no intervalo do Grupo Macaé.




Figura 2 - Carta estratigráfica da Bacia de Campos simplificada. (Modificada de Guardado et al., 2000, e parcialmente atualizada após Winter et al., 2007, in Melani, 2015).

## 2.2 GRUPO MACAÉ

Composto pelas Formações: Goitacás, Quissamã, Outeiro, Imbetiba e Namorado (Winter et al, 2007), o Grupo Macaé representa porção inferior da sequência pós-sal, com deposição carbonática em mar raso (Robaina et al, 1991). Dominado por carbonatos marinhos de águas rasas, o Grupo Macaé é caracterizado por uma associação de calcarenitos, calcirruditos e calcilutitos, depositados em ambiente de moderada a alta energia (Franz, 1987).

Segundo Spadini (2008), reservatórios carbonáticos albianos mostram grande variação de porosidade e permeabilidade. Altas permeabilidades correspondem à porosidade intergranular deposicional, enquanto baixas permeabilidades das rochas refletem predominância de microporosidade. Bruhn et al. (2003) define que as acumulações com idades albianas de petróleo têm controle estrutural, por falhas e dobras, e também estratigráfico, dado por variação lateral de fácies, com calcarenitos e calcirruditos gradando para calcarenitos, calcissiltitos e calcilutitos ricos em lama.

### **2.3 CAMPO B**

O Campo B é um reservatório fraturado carbonático do albian, produtivo a quase 40 anos. A cerca de 85km da costa, cobre uma área de 14km<sup>2</sup>. Composto predominantemente por calcarenitos e calcirruditos da Formação Quissamã distribuídos em bancos de areias carbonáticas de direção NE (Franz, 1987), o reservatório ocupa um bloco falhado, inserido em uma anticlinal, associado a duas falhas principais de crescimento que ocorrem a oeste e leste-sudeste do campo. (Franz, 1987).

Tomaso et al (2013) dividem o Campo B em duas zonas principais de acordo com intensidade de fraturamento: (1) área sul, onde predominam presença de fraturas e microporosidade; e área norte, região não fraturada com preservação de porosidade primária, havendo compartimentalização do reservatório em zona sul e zona norte.

Fraturas desempenham um importante papel na produção do campo, controlando e criando as condições necessárias para a produção de óleo (Franz, 1987). A origem destas fraturas no Campo B está intimamente ligada aos eventos causadores dos falhamentos regionais, sendo possível inferir ao menos dois estágios principais de fraturamento no reservatório. Primeiramente as fraturas foram totalmente cimentadas por calcita espática. Depois ocorrendo a reabertura e alargamento do sistema de fraturas, tornando estas falhas via preferencial de fluxo de fluido.

Tomaso et al (2007) ainda definem um limite superior para o reservatório no topo da formação Quissamã, com sua base sendo o contato óleo/água, não sendo possível identificar contato geológico relacionado.

### 3. METODOLOGIA

Divide-se o estudo em 8 fases distintas: (1) análise e apresentação de base de dados disponível, (2) processamento de atributos sísmicos para realce de descontinuidades, (3) estabelecimento de modelo estrutural, (4) definição de camadas e *upscaling* de *logs* de poços, (5) modelamento de propriedades, (6) classificação de zonas de interesse e cálculos de volume de hidrocarbonetos.

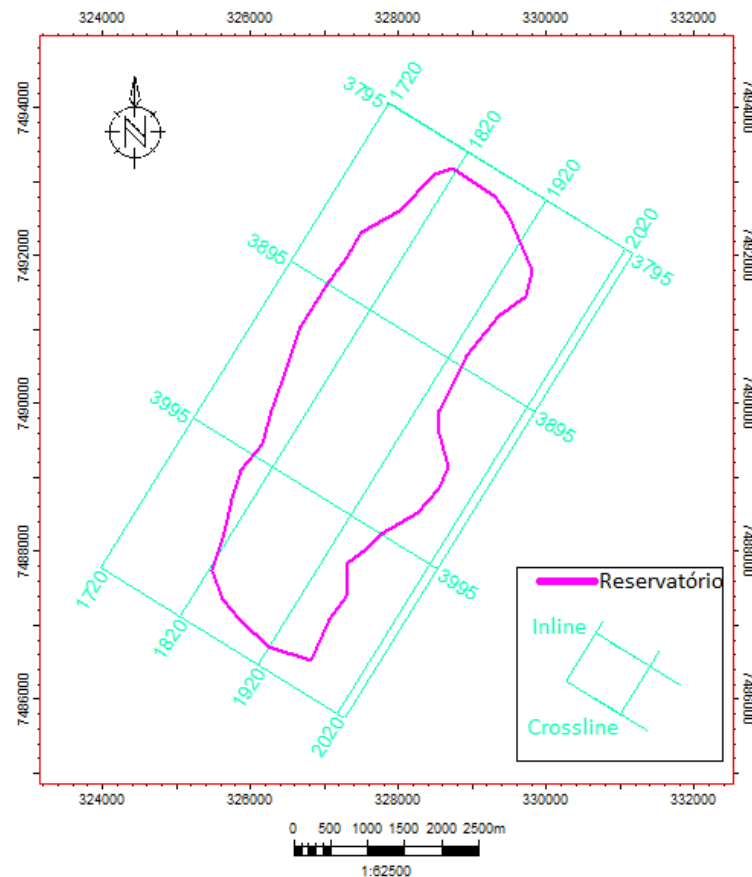
#### 3.1. Análise e apresentação de base de dados disponível

O volume sísmico 3D disponível para o estudo caracteriza-se por um volume pós-empilhamento convertido para o domínio do tempo por interpolações de velocidades de trânsito obtidas de *logs* sônicos de poço. Anteriormente à conversão de domínio sabe-se que o volume sísmico passou por processo de *normal moveout* e ganho em tempos maiores, embora não exista registro do histórico de processamento do volume.

Já convertido para o domínio da profundidade, o volume cortado tem uma área superficial de aproximadamente 28km<sup>2</sup> (Figura 3) e profundidades aproximadamente entre 1,9km e 4km, apresentando extensão vertical de pouco mais de 2km. Sendo composto por 296 *inlines* com espaçamento de 25m e 311 *crosslines* com espaçamento de 12.5m, o volume possui 8.5m de profundidade por amostra (4ms no dado em tempo) com 218 amostras por traço. Totalizando pouco mais de 20 milhões de amostras.

Horizontes inicialmente interpretados no domínio do tempo e convertidos para o domínio da profundidade conjuntamente ao volume sísmico também fazem parte da base de dados, estes horizontes representam os topos das Formações Outeiro, Imbetiba, Quissamã e Lagoa Feia (Figura 4) assim como o contato óleo-água na base do reservatório e o limite superior de ocorrência de água no reservatório. Assume-se que o topo de uma formação corresponde à base da unidade que a sobrepõe. A Tabela 1 traz as profundidades em que os horizontes são encontrados.

Os dados de poço disponibilizados referem-se à poços que interceptam ou localizam-se próximos ao reservatório (Figura 5) e encontram-se em situações diferentes de disponibilidade de logs e profundidades em que os dados são disponibilizados. A Tabela 2 traz a relação de disponibilidade de dados para cada um dos 47 poços estudados.

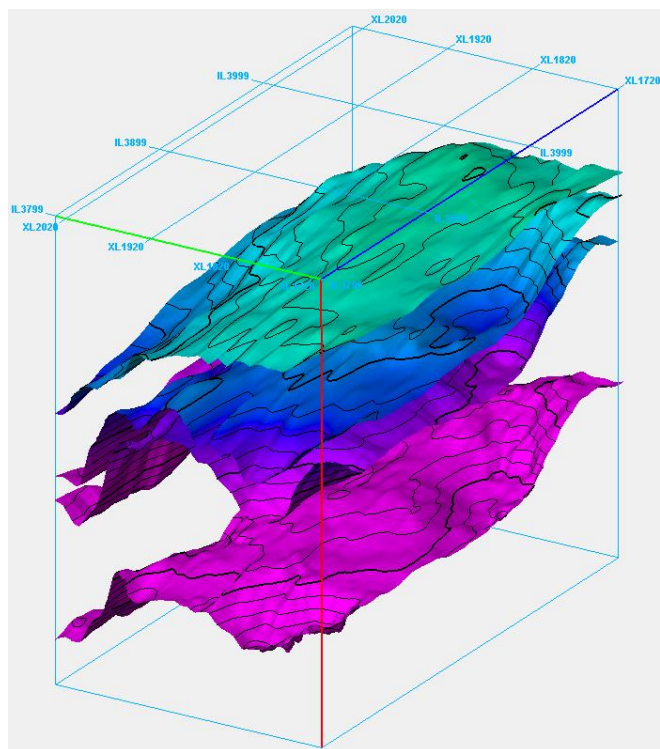


**Figura 3 - Extensões em superfície do reservatório e do volume sísmico no domínio da profundidade. Números ao redor da extensão do volume sísmico correspondem à crosslines e inlines.**

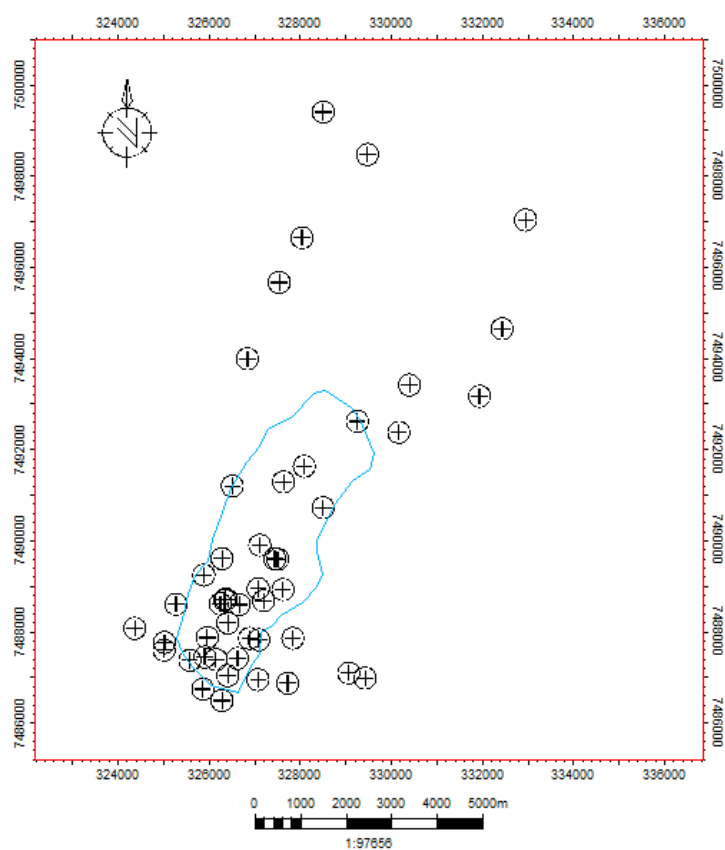
**Tabela 1 - Profundidades dos horizontes carregados. O horizonte 'OWC' representa o contato óleo-água (Oil Water Contact) enquanto o horizonte 'Água Até' representa as profundidades mais rasas com conteúdo de água dentro do reservatório.**

Profundidades			
Horizonte	Inicial (m)	Final (m)	Média (m)
Imbetiba	1997	2332	2083
Outeiro	2080	2540	2277
Quissamã	2184	2642	2376
Água Até	2395	2461	2431
OWC	2438	2502	2483
Lagoa Feia	2576	2976	2755





**Figura 4 - Horizontes carregados - De cima para baixo: Formação Outeiro, Formação Imbetiba, Formação Quissamã e Grupo Lagoa Feia. Cubo no entorno representa os limites do volume sísmico com profundidades de 1798m até 3076m**



**Figura 5 - Localização dos 47 poços estudados, ícones representam as coordenadas em que os poços têm sua maior profundidade, não sua localização em superfície.**



**Tabela 2 - Relação de disponibilidade de logs para cada poço estudado. A coluna de saturação de água diz respeito as 4 curvas determinadas por Melani et al. (2015), visto que, para os poços em que elas estão disponíveis, as 4 curvas encontram-se disponíveis.**

Sigla Perfil Unidade	GR Raios gama gAPI	ILD Resistividade ohm.m	PHIE Porosidade Efetiva m3/m3	RHOB Densidade g/cm3	SW Saturação de água %
B_1	X	X	X	X	X
B_2	X	X		X	
B_4D	X	X	X	X	X
B_5D	X	X	X	X	X
B_17	X	X	X	X	X
B_19D	X	X	X	X	X
B_22	X	X	X	X	X
B_22D		X	X	X	X
B_24D	X	X	X	X	X
B_25D	X	X	X	X	X
B_26D	X	X	X	X	X
B_27D	X	X	X	X	X
B_29	X	X	X	X	X
B_30	X	X	X	X	X
B_35D	X	X	X	X	X
B_36D	X	X	X	X	X
B_38	X	X	X	X	X
B_39D	X	X	X	X	X
B_49D	X	X		X	
B_322	X	X	X	X	X
B_32D	X	X	X	X	X
B_41D	X	X	X	X	X
B_42D	X	X	X	X	X
B_43D	X	X	X	X	X
B_47D	X	X	X	X	X
B_3D	X	X	X	X	X
B_23D	X	X	X	X	X
B_28D	X	X	X	X	X
B_34D	X	X	X	X	X
B_6D	X	X		X	
B_9D	X	X		X	
B_34D	X	X		X	
B_131	X	X		X	
B_197	X	X		X	
B_237	X	X			
B_321A	X	X		X	
B_323	X	X		X	
B_410	X	X		X	
B_448	X	X		X	
B_449	X	X		X	
B_466	X	X		X	
B_18D	X	X		X	
B_51HP	X	X		X	
B_33DA	X	X	X	X	X
B_37	X	X	X	X	X
B_40	X	X	X	X	X
B_195	X	X	X	X	X
B_41	X	X		X	
B_44	X	X		X	

Os dados de porosidade efetiva (PHIE) e saturação de água (SW) são modelados neste estudo, pois são as propriedades que influenciam os cálculos de volume desenvolvidos. Modela-se também os dados de densidade (RHOB), resistividade (ILD) e raio gama (GR) para fornecer maiores dados em tentativas de classificação automática de fácies. Os dados de porosidade efetiva, densidade, resistividade e raio gama foram fornecidos de maneira direta pela Agência Nacional de Petróleo (ANP). Já os dados de saturação de água são representados por 4 curvas de saturação calculadas por Melani et al. (2015) utilizando a equação de Archie:

$$S_w^n = \frac{a \cdot R_w}{\Phi^m \cdot R_t} \quad (3.1.1)$$

Onde  $\Phi$  é a porosidade efetiva,  $S_w$  é o valor calculado de saturação de água,  $R_w$  representa a resistividade da água,  $R_t$  é a resistividade real da rocha,  $a$  é o fator de tortuosidade,  $m$  é o fator de cimentação e  $n$  é o fator de saturação. As quatro curvas assumem um valor constante de 1 para o fator de tortuosidade ( $a$ ) devido a não existência de dados laboratoriais. Os valores de fator de cimentação ( $m$ ) e saturação ( $n$ ) são diferentes para cada curva (Tabela 2).

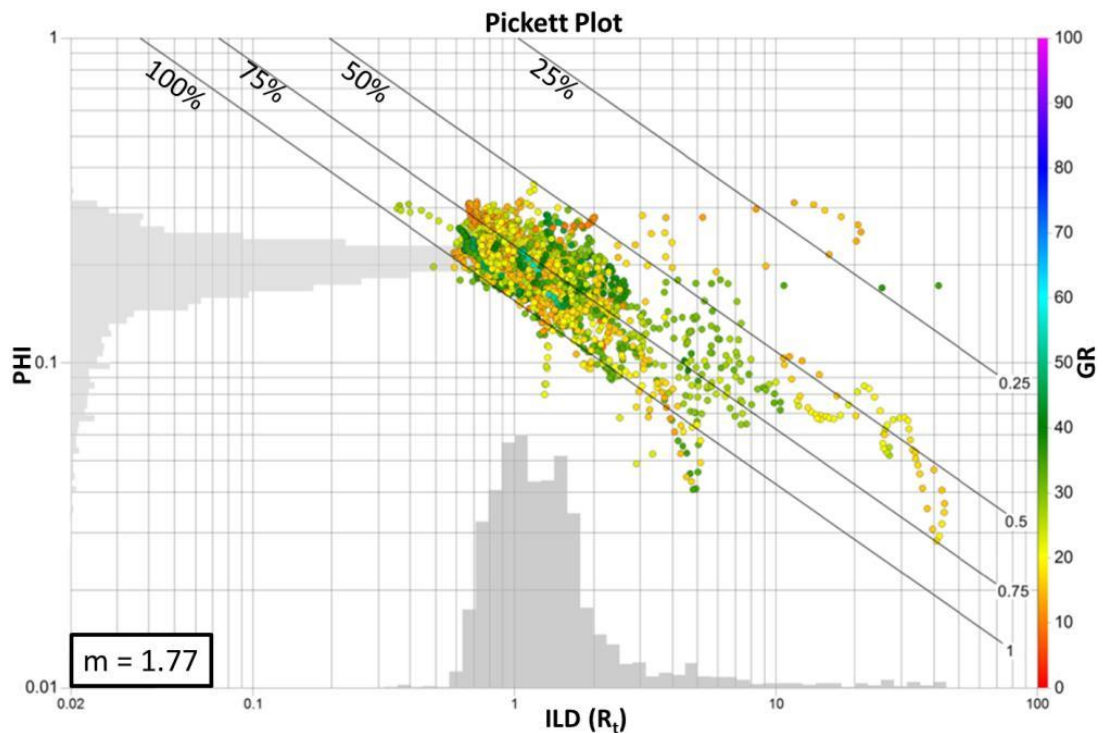
**Tabela 3 - Fatores de cimentação e saturação para cada um dos cenários de cálculo de saturação de água. De Melani et al. (2015)**

Archie's Parameters		
Sw Scenarios	m	n
C1	2	2
C2	1.77	2.4
C3	1.95	3.43
C4	2.25	4.24

O cenário C1 utiliza valores empíricos tradicionais de  $m$  e  $n$  para reservatórios carbonáticos (Glover, 2011). C2 utiliza uma análise de *Pickett plot* para definir  $m$  e define  $n$  baseado no menor valor medido em laboratório para um reservatório análogo (Elias & Steagall, 1996). C3 assume o valor médio de medidas de laboratório para testemunhos de 2 poços do Campo B para  $m$  e o valor médio de todas as medidas de

laboratório para um reservatório análogo para n. C4 assume m e n como os maiores valores medidos em laboratório para um reservatório análogo.

O método da análise de Pickett plot utilizado no cenário C2 consiste num gráfico log-log de resistividade e porosidade efetiva. Pontos de mesma saturação de água ( $S_w$ ) neste gráfico podem ser caracterizados por linha retas paralelas na distribuição dos valores e o fator de cimentação (m) é definido pelo coeficiente angular destas linhas (Figura 6).



**Figura 6 - Pickett Plot utilizado na determinação do fator de cimentação ( $m = 1,77$ ). De Melani et al. 2015.**

O fator de cimentação (m) é entendido como um modelo da influência do sistema de poros na resistividade da rocha, uma vez que se assume que a matriz é não condutora. Relacionando assim o fator de cimentação à permeabilidade da rocha, uma vez que altos valores de permeabilidade reduzem o fator de cimentação. O fator de saturação (n) modela o comportamento da condutividade de fluidos no espaço poroso da rocha e relaciona-se com a molhabilidade da rocha. Rochas em ambientes aquosos, para baixos valores de saturação de água, formam uma camada fina de água ao longo das paredes dos poros, tornando a rocha condutiva. Ao mesmo tempo, rochas em meio à óleo são caracterizadas por gotas descontínuas de água no espaço poroso, reduzindo a condutividade da rocha (Ellis & Singer, 2008).

### 3.2. Processamento de atributos sísmicos para realce de descontinuidades.

Os atributos processados nesta etapa são processados utilizando os fluxos de trabalho disponíveis no software *Schlumberger Petrel*, com licença disponibilizada ao laboratório de informática do Departamento de Engenharia do Petróleo – DEP, da Universidade Estadual de Campinas. O Campo B é descrito na literatura como um reservatório fraturado que se encontra inserido em uma anticlinal de eixo com direção aproximadamente NW, assim a caracterização estrutural do reservatório mostra-se como importante etapa na definição de sua geometria e limites, fatores diretamente relacionados ao cálculo de volumes no reservatório.


Atributos sísmicos caracterizam-se por qualquer característica quantitativa calculadas com base nos valores de amplitude originais de um volume sísmico (Taner et al, 1979; Bjorlykke, 1989). Atributos sísmicos, de maneira geral, procuram realçar ou suprimir alguma característica observada no volume sísmico de amplitudes original. Seja o realce de descontinuidades, de refletores ou um aprimoramento da razão sinal-ruído, entre outros (Bahorich & Farmer, 1995; Brown, 1999).

O processo de caracterização estrutural de um reservatório é um processo tradicionalmente repleto de subjetividades relacionadas à interpretação do usuário. Assim, a utilização de fluxos de trabalho baseados em atributos sísmicos possibilita a remoção de vieses interpretativos associados ao processo (Cox & Seitz, 2007).

O atributo de variância é largamente considerado como um atributo que realça a descontinuidade de volumes sísmicos e sua utilização na caracterização estrutural de reservatório é sugerida por diversos autores (Pedersen et al, 2005; Fletcher et al, 2011; Cox & Seitz, 2005; Silva et al, 2005; Chopra & Marfurt, 2007; Rijks & Jauffred, 1991; Bruno et al, 1998).

O atributo de *ant-tracking* mostra-se como uma técnica de realce de valores contínuos em um volume e sua utilização com *inputs* de atributos de realce de descontinuidades é aceito como satisfatório em processos de classificação estrutural (Pedersen et al, 2005; Cox & Seitz, 2005; Silva et al, 2005), especialmente em litologias com elevadas heterogeneidades associadas como reservatório fraturados e/ou carbonáticos (CSM, 2012; Chahine et al, 2014; Zeng & Kerans, 2003).

Baseado nisto, Ralha (2016) utiliza um fluxo de trabalho para o processamento de atributos sísmicos para o realce de descontinuidades no Campo B baseado nos atributos de variância e *ant-tracking*. Ao mesmo tempo, outros autores sugerem a utilização de filtros de suavização estrutural previamente ao cálculo do atributo de variância à fim de reduzir os efeitos de ruídos nas estruturas caracterizadas (Randen et al., 2001; Zhao et al., 2015; Basir et al., 2013). Define-se assim para este estudo um fluxo de trabalho caracterizado por filtro de suavização estrutural inicial aplicado às amplitudes no domínio da profundidade e utilizados como input para cálculo de atributo de variância, que por sua vez é utilizado como input no algoritmo de *ant-tracking* (Figura 7).



**Figura 7 - Fluxo de trabalho para geração de volumes de ant-tracking.**

O filtro de suavização estrutural é um filtro aplicado diretamente a amplitudes sísmicas que aplica suavização por um filtro gaussiano paralelo à orientação de refletores (Schlumberger, 2015; Hale, 2009). A aplicação do filtro de suavização estrutural aprimora, em especial para litologias carbonáticas, a continuidade de refletores bem como colabora com a supressão de ruídos (Randen et al., 2001).

O principal parâmetro de configuração do filtro é o espaço amostral para filtragem em cada traço, o espaço amostral pode ser definido tanto verticalmente quanto nas direções de *crossline* e *inline* e tem, no software Schlumberger Petrel, valor padrão de 1.5 amostras e é o valor utilizado neste estudo. Ou seja, para cada amostra

no volume original, a suavização leva em conta 1.5 amostras em cada direção e sentido.

O filtro Gaussiano em 3 dimensões é definido pela equação:

$$h_G(x, y, z) = \frac{1}{(\sqrt{2\pi} \sigma)^3} \exp\left(-\frac{x^2 + y^2 + z^2}{2 \sigma^2}\right) \quad (3.2.1)$$

Onde  $h_G$  representa o valor de amplitude após a aplicação do filtro,  $x$ ,  $y$  e  $z$  representam os espaços amostrais em cada direção e  $\sigma$  representa o desvio padrão das amplitudes dentro deste espaço amostral (Ponte., 2019).

O atributo de variância é calculado em três dimensões e representa a variância traço a traço da amplitude original num mesmo espaço vertical de tempo/profundidade ou paralelamente à um refletor. O cubo de variância caracteriza-se pelo cálculo de variâncias normalizadas das amplitudes convertidas para uma mesma fase em espaços amostrais definidos pelo usuário (Randen et al., 2000; Van Bemmelen & Pepper, 2000). Ou seja, para cada amostra, o seu valor no cubo de variância será a variância estatística dos módulos das amplitudes no espaço amostral bidimensional definido normalizada para valores entre 0 e 1. Tal qual:

$$V = \frac{\sigma^2}{\sum_{i=1}^N A^2} \quad (3.2.2)$$

Onde  $V$  é o valor do atributo de variância em cada amostra,  $\sigma$  é o desvio padrão das amplitudes dentro do espaço amostral selecionado (com  $\sigma^2$  sendo a variância estatística),  $A$  é amplitude de cada amostra e  $N$  é o total de amostras no espaço amostral. Os valores padrões utilizados para o espaço amostral são de 3 *inlines* e 3 *crosslines* em cada direção, totalizando 36 amostras de amplitude para cada valor de variância.

O atributo de *ant-tracking* baseia-se em conceitos de inteligência de enxame mimetizando colônias reais de formigas. O conceito de inteligência de enxame se refere ao comportamento coletivo de grupos de insetos. Formigas no mundo real

utilizam feromônios para marcar o caminho percorrido em sua busca por comida. Analogamente, o atributo de *ant-tracking* utiliza-se de uma grande quantidade de agentes distribuídos ao longo de um volume de descontinuidades. Estes agentes, representando formigas no modelo, designam feromônios às áreas correspondentes a altos valores de descontinuidade e, por um processo iterativo, traçam o menor caminho entre seu ponto de origem (seu ninho) e altos valores de variância (Pedersen et al, 2005). Os pontos de origens das formigas são definidos dividindo o volume de variâncias em sub volumes de mesmo tamanho para cada formiga e tomando como a origem os máximos locais de variância, garantindo assim que o caminho traçado corresponde a descontinuidades (Chen et al, 2018).

A definição específica do algoritmo de *ant-tracking* é protegida por patente concedida à companhia *Schlumberger*. Chen et al (2018), no entanto, sugerem um algoritmo similar caracterizado pela utilização de amplitudes como altitudes em um modelo imitando um modelo topográfico e formigas navegando o relevo virtual em busca do menor caminho possível. Esta alternativa, embora bem definida matematicamente por funções de gradientes locais, limita-se a dados sísmicos bidimensionais, utiliza como entrada o volume sísmico de forma direta e, diferentemente do algoritmo de *ant-tracking*, não possui extensa validação de uso estabelecida na literatura científica.


O atributo de *ant-tracking* caracteriza-se por uma série de parâmetros como: distância limite entre formigas, desvio de trilha, tamanho de passo, passos ilegais permitidos, passos legais necessários e critério de parada. A tabela 4 traz a definição destes parâmetros e os valores utilizados para cada um deles. A escolha dos parâmetros afeta a sensibilidade da resposta encontrada no volume de *ant-tracking* aos valores de variância. No entanto, como o fluxo de trabalho definido busca a supressão de ruídos não relacionados a feições estruturais previamente ao cálculo de variâncias, a definição de parâmetros para o volume passa a ser uma decisão entre o realce de feições regionais ou descontinuidades em menor escala. Assim, os parâmetros utilizados baseiam-se nas configurações do software *Petrel* para reservatórios fraturados (Schlumberger, 2015; Fang et al, 2016).

O cubo de *ant-tracking* resultante do processo é composto por valores entre -1 e 1 para cada amostra do volume original, onde -1 representa um volume inteiramente

homogêneo e contínuo enquanto 1 representa um volume teórico inteiramente descontínuo (Chahine et al., 2015). Ao mesmo tempo, medidas de grau de fraturamento obtidas de testemunhos correlacionam-se com valores de *ant-tracking* de -0.8 até 0, enquanto que valores muito próximos de 1 indicam refletores distribuídos de maneira caótica e normalmente são observados apenas em depósitos de sal (Godfrey & Bachrach, 2008).

O processo de individualização de estruturas é tradicionalmente realizado manualmente com base em interpretações do operador, consumindo grande quantidade de tempo e inserindo um alto grau de subjetividade às interpretações estruturais. Em especial para reservatórios fraturados, como o estudado, devido ao alto número de feições a serem identificadas. Fang et al. (2016) sugerem que o limite de detecção de estruturas individuais no volume de *ant-tracking* seja de 200m, assim, apenas descontinuidades que tenham extensão superior a 200m em alguma direção são consideradas no processo de modelamento, embora altos valores de *ant-tracking* ainda apresentem alta correlação com densidade de fraturas mesmo em regiões onde as descontinuidades não podem ter sua localização precisamente determinada devido à resolução do atributo.

Com um volume de realce de descontinuidades como o volume de *ant-tracking* é possível caracterizar áreas do volume sísmico como contínuas ou descontínuas de forma objetiva e veloz, permitindo realizações iterativas dos processos para melhor definição de parâmetros. Assim dando maior robustez e um maior nível de controle de qualidade aos dados gerados. A figura 8 traz o fluxo de trabalho estabelecido aplicado à uma seção arbitrária do volume sísmico disponibilizado para este estudo.



**Figura 8 - Visualização do fluxo de trabalho utilizado identificando uma descontinuidade.**

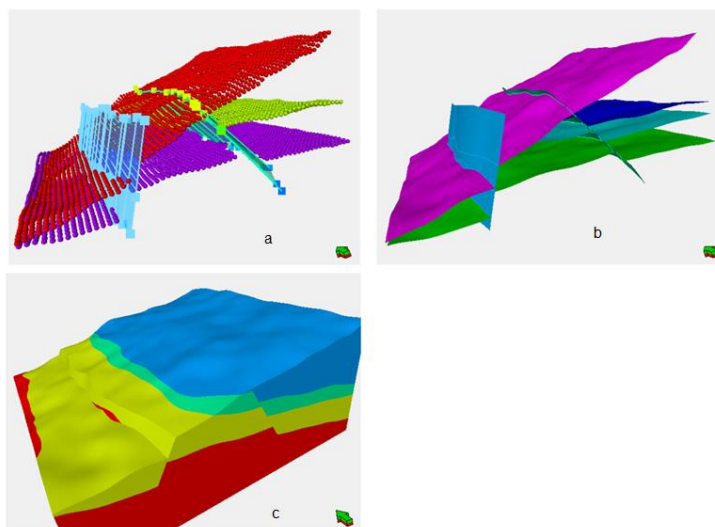


**Tabela 4 - Definição de parâmetros para o atributo de ant-tracking e valores utilizados no processamento do atributo. Os valores tomados para cada parâmetro seguem os valores sugeridos na literatura para reservatórios fraturados. Baseado em Schlumberger (2015).**

Parâmetro	Valores			Definição do Parâmetro
	Utilizado	Mínimo	Máximo	
Distância Limite entre Formigas	5	1	30	Distância mínima em voxels entre ninhos.
Desvio de Trilha	2	0	3	Número de voxels em cada direção que o agente procura por valores. Maiores valores permitem maior conectividade entre descontinuidades, mas podem gerar feições que não mantem fidelidade à sísmica.
Tamanho de Passo	3	2	10	Distância em voxels que o agente procura pelo valor máximo local na próxima iteração de busca. Valores maiores geram resultados que representam tendências estruturais enquanto menores valores geram resultados de maior resolução.
Passos Ilegais Permitidos	2	0	3	Um passo ilegal é um passo onde o agente não encontra nenhum valor de descontinuidade dentro dos parâmetro estabelecidos e procura o valor máximo dentro dos parâmetros direcionais. Este parâmetro define o número máximo de passo ilegais sequenciais antes que o agente encerre a busca por valores.
Passos Legais Necessários	2	0	3	Número de passo legais necessários para que seja permitido ao agente tomar um passo ilegal uma vez que o agente alcance o número máximo de passos ilegais sequenciais.
Critério de Parada	10	0	50	Porcentagem máxima de passos ilegais tomados durante a identificação de uma descontinuidade para que ela seja considerada como uma descontinuidade e não como ruído.

### 3.3. Estabelecimento do modelo estrutural.

Uma vez que descontinuidades sejam individualizadas pelo processo de *ant-tracking* é possível integrar estas descontinuidades num modelo estrutural do reservatório. A definição de um modelo estrutural é o processo da combinação de dados de interpretação de estruturas e horizontes para formar um modelo volumétrico entre as superfícies interpretadas (Figura 9).



**Figura 9 - Exemplo de fluxo de trabalho para modelamento estrutural. Os dados de interpretações de estruturas e horizontes são inicialmente carregados (a) para então horizontes serem modificados de acordo com sua relação com estruturas que os interceptam (b) e finalmente é gerado um modelo volumétrico de zonas com base nas superfícies modeladas (c). Alterado de Schlumberger (2015).**

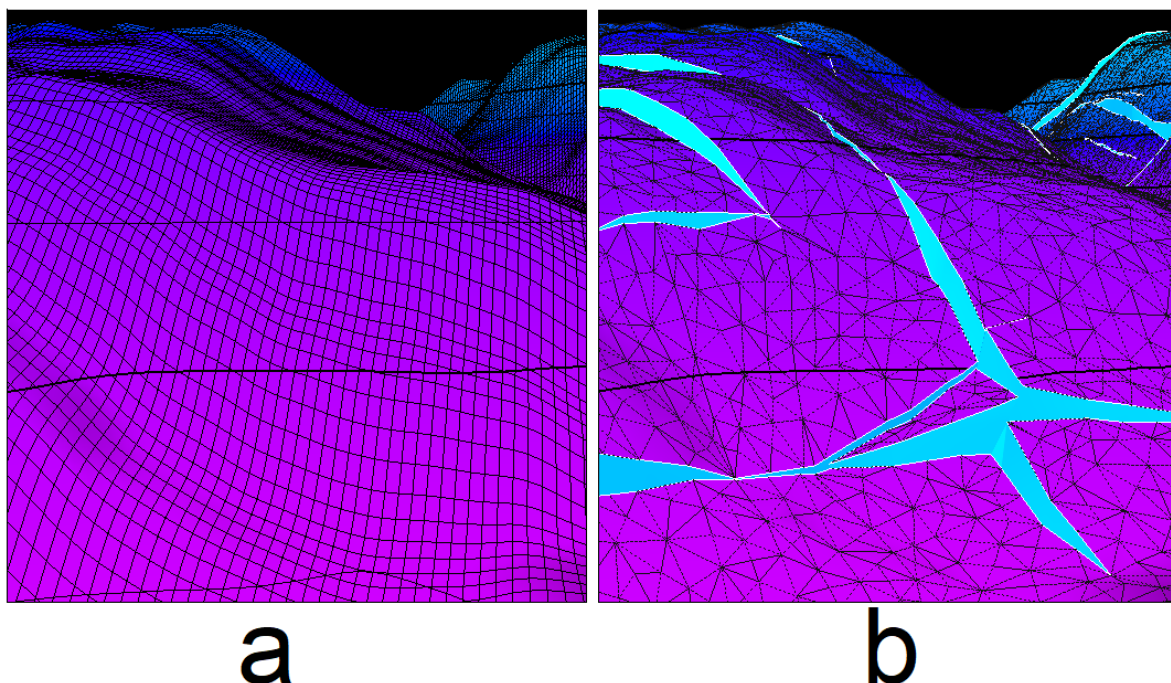
A primeira etapa no estabelecimento de um modelo estrutural é a definição da geometria do *grid* onde o modelo será gerado, em seguida estabelece-se relações entre as estruturas interpretadas em suas intersecções e finalmente definem-se as relações entre estruturas e horizontes em suas intersecções.

Neste estudo, o modelo estrutural gerado utiliza de *grids* de mesma geometria do volume sísmico, cobrindo a área total com disponibilidade de dados de sísmica e, consequentemente, de *ant-tracking*. O *grid* utilizado para o modelamento de estruturas utiliza células cúbicas de 100m de lado, totalizando pouco menos de 40 mil células. Enquanto o *grid* utilizado para modelar os horizontes é composto por células bidimensionais paralelas ao horizonte de 25m de comprimento na direção dos *inlines*

e 50m na direção dos *crosslines*, totalizando pouco mais de 22 mil células por horizonte.

A etapa de relações entre interseções estrutura-estrutura define-se pela classificação para cada intersecção de qual estrutura encontra-se truncada por qual. Ao mesmo tempo, a etapa de relações entre interseções estrutura-horizonte define-se pelo estabelecimento de direções de movimentação em cada lado da estrutura.

Uma vez que o modelo inclui 411 estruturas diferentes, o processamento de relações em interseções é feito de maneira automática. Para as interseções estrutura-estrutura a estrutura de maior área superficial é considerada como a dominante, com a estrutura de menor área sendo truncada. Justifica-se este processo pelo fato de estruturas de maior área serem associadas a maiores valores de *ant-tracking*, refletindo assim em uma região provavelmente associada a maiores níveis de fraturamento. Para as interseções estrutura-horizonte, os horizontes são modificados pelas estruturas de acordo com as propriedades de mergulho e direção de movimentação obtidas na extração automática de descontinuidades (Figura 10). Com as superfícies modeladas, tem-se definidas as delimitações do modelo, sendo possível gerar um modelo de zonas para a área estudada e a definição de volumes de rocha em cada zona. A resolução inicial do modelo volumétrico é a mesma do *grid* de estruturas, sendo refinado posteriormente para o modelamento de propriedades ao longo das zonas.




**Figura 10 - Horizonte do topo Quissamã. (a) Mostra o horizonte originalmente carregado. (b) Mostra o horizonte modificado pelas interseções com estruturas. Áreas em azul representam superfícies de feições estruturais.**

### **3.4. Definição de Camadas e *Upscaling* de Logs de Poços**

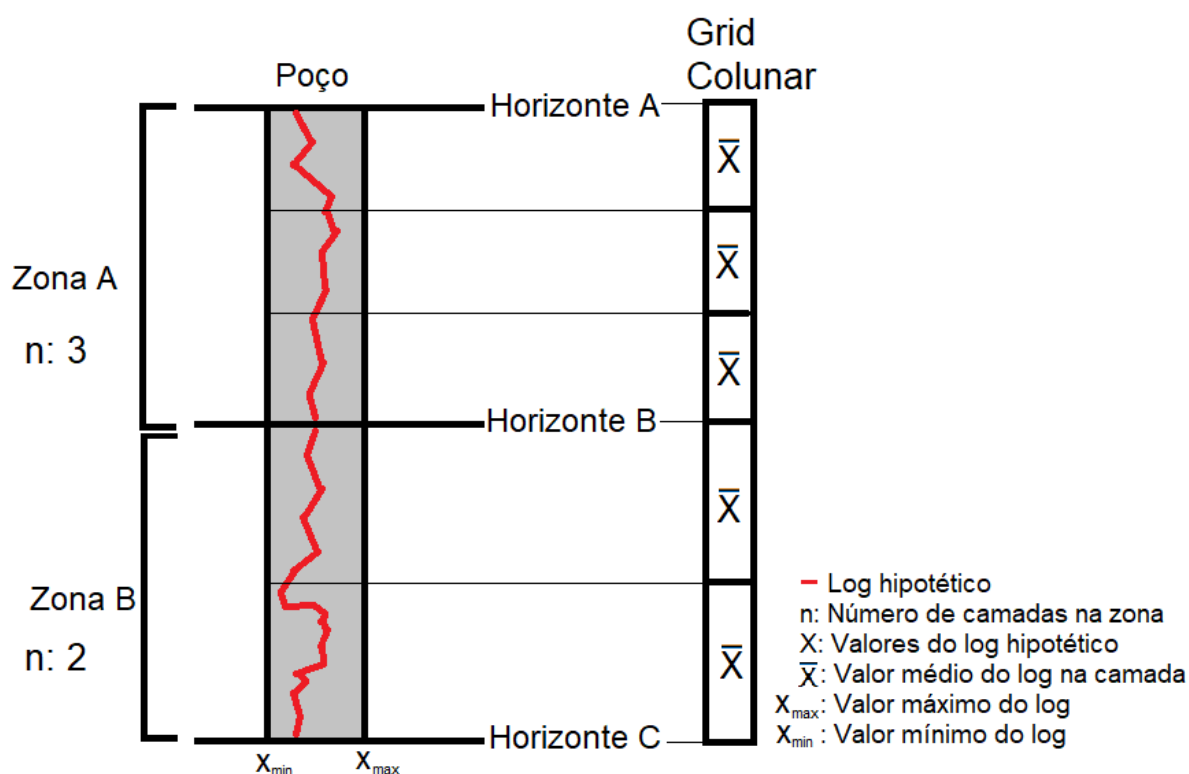
Devido a diferença de resolução entre os dados de poço e o modelo construído, antes que o modelo possa ser populado com valores para cada propriedade, é necessária que seja realizado o *upscaling* das propriedades de poço para a escala do modelo.

O primeiro passo para realização do *upscaling* é a definição do *grid* em que as propriedades serão modeladas. A resolução horizontal do *grid* é mantida igual a do *grid* de horizontes, com células de 25m por 50m, a resolução vertical do *grid* é determinada pelo número de camadas no modelo. As camadas do modelo proporcionam os limites verticais do modelo e podem ser estabelecidas para cada zona. Neste estudo opta-se pela utilização de camadas paralelas aos horizontes e com 5 metros de espessura para capturar com maior detalhe variações verticais nos dados, visto que a fonte principal de dados a serem modelados são logs de poço (Figura 11). O *grid* após a delimitação das camadas possui pouco menos de 12 milhões de células.




**Figura 11 – (a) Modelo volumétrico de zonas com camadas definidas e (b) Zona do Quissamã entre os horizontes do Quissamã e do Lagoa Feia isolado do resto do modelo.**

Com o *grid* definido, um segundo *grid* unidimensional vertical é definido com células correspondentes a cada camada. As células deste *grid* são posicionadas ao longo do caminho de cada um dos poços estudados e um processo de média móvel ao longo das células é utilizado para o *upscaling* dos dados (Figura 12). Ou seja, para cada *log* em cada poço os valores atribuídos a cada célula correspondem a média dos valores deste *log* no espaço amostral correspondente à célula. O resultado deste processo é uma série de *grid* colunares para cada propriedade a ser modelada espalhados pelo volume do modelo de camadas (Figura 13).



**Figura 12 – Diagrama do funcionamento do algoritmo de upscaling de dados de poço para a escala do modelo. Para cada célula do grid colunar é atribuído um valor para cada log correspondente ao valor médio do log no espaço amostral correspondente à célula.**



**Figura 13 - Grid colunares de porosidade efetiva (PHIE) cortados para a região entre o topo do Quissamã (superfície em roxo) e o contato óleo-água (superfície em preto).**

### 3.5. Modelamento de Propriedades

O modelamento de propriedades trata-se da utilização de técnicas de geoestatística para a população do modelo com valores para as propriedades de poço após o *upscaling* para a escala do modelo de camadas. Previamente a seleção de uma técnica de modelamento é necessário análise dos dados de input do modelamento, uma vez que cada técnica parte de uma série de pressupostos sobre o dado original.

Dado que o modelo estrutural e de camadas definidos anteriormente buscam o estabelecimento do modelo físico do reservatório, assume-se que o modelo físico é conhecido. Ao mesmo tempo, tem-se a informação a priori de que o modelamento é realizado em rocha reservatório, assim assume-se que existe auto correlação espacial das variáveis.

Técnicas de Krigagem podem ser definidas por estimativas de valores em um volume embasadas numa ponderação de todas as amostras, tendo que o peso de cada amostra é obtido com a condição restritiva de que a soma dos pesos seja igual a 1 e a variância das estimativas seja mínima (Oliveira, 1997). Tal que, para um conjunto de  $n$  amostras  $\{x_1, x_2, \dots, x_n\}$ :

$$Z_S = \sum_{i=1}^n \lambda_i x_i \quad (3.5.1)$$


Onde  $Z_S$  é o valor estimado para cada localização  $S$  do grid ou modelo,  $\lambda_i$  é um peso desconhecido para cada  $i$ -ésima amostra  $x_i$ . No caso de interpolações baseadas no inverso da distância entre pontos, o peso  $\lambda_i$  depende apenas da distância entre cada local  $S$  e as amostras. Para métodos de krigagem os pesos  $\lambda_i$  são obtidos a partir de estimativas originadas da regressão linear entre os pontos em um variogramas (ESRI, 2019).

A Krigagem com Deriva Externa (KDE) é um algoritmo derivado da Krigagem Ordinária por Deutsch & Journel (1992) e Wackernagel (1995) mostra-se como



ferramenta de grande utilidade para estimativas em reservatórios onde evidencia-se auto correlação espacial dos atributos a serem modelados (Zanão, 2008). Segundo Hengl (2009) principal diferencial do algoritmo de Krigagem com Deriva Externa em relação a Krigagem ordinária se dá na prévia utilização de uma regressão linear entre as amostras para então utilizar os erros da regressão linear (chamados de residuais ou deriva) como valores para a krigagem (Figura 14).

No entanto, a utilização do algoritmo de Função Gaussiana Aleatória de Simulação (Gaussian Random Function Simulation - GRFS) incorpora algoritmos de KDE com simulações estocásticas no campo não estruturado dos variogramas, honrando de maneira mais efetiva variações locais no dado de entrada (Schlumberger, 2015), ainda que o GRFS tenha como pressuposto a distribuição aproximadamente normal dos valores de entrada.



**Figura 14 - Ilustração da obtenção de valores residuais para métodos de Krigagem com Deriva Externa (aqui denominado como regression-kriging). De: Hengl (2009).**

Assumindo que os dados de entrada do modelamento estejam sob distribuição normal, o algoritmo de GRFS mostra-se superior a algoritmos de Krigagem pois é um algoritmo estacionário no domínio espacial do dado, mantendo valores de média e variância constantes ao longo do modelo, dando realce a variâncias locais (Daly &



Caers, 2010; Dongas, 2016; Benabbou et al., 2015). Assim, utiliza-se o algoritmo de GRFS quando se verifica distribuição normal dos dados de propriedades após *upscaling* e o algoritmo de KDE quando não é verificada distribuição normal. Em ambos os algoritmos são utilizados variogramas com direção azimutal de 30 graus, direção paralela ao eixo da anticlinal em que o reservatório é incluso e aproximadamente paralela à direção dos *crosslines*. Os variogramas também são do tipo esférico e são caracterizados por distância máxima de anisotropia de 3500m horizontalmente (aproximadamente metade da menor dimensão do modelo) e 10m na direção vertical (equivalente a 2 células no grid colunar)

Ao mesmo tempo, a distribuição dos dados de poço comparada com a distribuição dos dados após *upscaling* e dos dados após o modelamento é utilizada como controle de qualidade dos dados de modelamento.

Propriedades geométricas como espessura do reservatório e distância para falhas também são computadas. Propriedades geométricas são medidas simples de distâncias e volumes de cada célula com referência a outro atributo do modelo. Também é computada uma propriedade baseada no volume de *ant-tracking* tomando valores médios do atributo sísmico para cada célula.

### **3.6. Classificação de Reservatório e Cálculos de Volume de Hidrocarbonetos.**

Uma vez que as células do modelo são populadas com valores para cada uma das propriedades, é possível classificar o modelo de acordo com qualquer parâmetro de classificação baseado nestas propriedades.

Tradicionalmente, zonas de interesse em reservatórios são definidas pela definição binária de zonas dos logs de poço em zonas de *net pay* ou não, ou seja, uma classificação binária sobre a viabilidade de produtividade de uma porção do log de poço. Esta classificação é feita atribuindo valores de corte mínimos para cada um dos logs utilizados na estimativa (geralmente porosidade e saturação de água) e considerando como não viável qualquer área em que os valores para um dos logs seja inferior ao valor de corte definido para esta medida. Embora largamente utilizado, este

método tem suas limitações devido à natureza booleana das classificações assim como introduz um grau de subjetividade na definição dos valores de corte (Cobb et al, 1998).

Dada a existência de um modelo espacial para as propriedades de saturação de água e porosidade como o obtido no processo de modelamento, este estudo busca realizar a classificação de zonas de interesse de maneiras distintas que aproveitem a disponibilidade deste modelo. Em seguida, calcula-se os valores de volume de poros de hidrocarbonetos (*Hydrocarbon Pore Volume* – HCPV) para a zone de interesse para cada um dos métodos utilizados, dado que o cálculo de volume é definido por:

$$HCPV = \sum_{i=1}^n V_B \varphi_E (1 - S_w) \frac{V_P}{V_B} \quad (3.6.1)$$

Onde HCPV é o volume de hidrocarbonetos,  $n$  é o total de células do modelo,  $V_B$  (*bulk volume*) é o volume total da célula,  $\varphi_E$  é o valor da propriedade de porosidade efetiva para a célula,  $S_w$  é o valor da propriedade de saturação de água para a célula e  $V_P$  (*pay volume*) é o volume da célula considerado como *net pay*. A relação entre  $\frac{V_P}{V_B}$  é chamada de razão *Net-to-Gross*, ou N/G. Nos métodos de classificação booleanos tradicionais, a razão N/G é definida como 0 ou 1 dependendo dos valores de corte definidos previamente, ou seja, cada célula contribui de maneira completa ou não contribui para o cálculo de volumes. Entre os métodos sugeridos neste estudo, alguns deles utilizam razões N/G booleanas enquanto outros usam razões variáveis de 0 a 1. Para reduzir o número de saídas dos cálculos de volume, na etapa de avaliação dos métodos sugeridos, os valores de saturação de água sempre correspondem à curva do cenário C2, pois esta apresenta maior grau de correlação com os dados de testemunho do Campo B (Melani et al, 2015).

Cada um dos métodos apresentados tem então cálculos de HCPV realizados com base em sua razão N/G. Os volumes são então comparados com cálculos de HCPV obtidos com base nas classificações de perfis de poço em *net pay* ou não realizadas por Melani et al. (2015). Para o cálculo de volumes baseados nos estudos de Melani et al. (2015) realiza-se o *upscaling* das classificações de poço para um grid colunar assim como descrito em 3.4, exceto que, para manter a natureza binária da

propriedade, o valor da célula é a moda no espaço amostral e não a média. O modelo é populado por uma propriedade onde cada célula tem um valor de razão N/G booleano correspondente ao valor da célula mais próxima no grid colunar.

### **3.6.1. Valores de cortes baseados em análise estatística simples de propriedades.**

Tendo populado o modelo com valores para cada uma das propriedades, é possível aplicar valores de corte às propriedades modeladas para definição booleana de razões N/G. Assume-se N/G igual a zero para células em que qualquer um dos valores de propriedades de saturação de água ou porosidade se encontre abaixo do valor de corte definido. Valores de corte são definidos de acordo com percentis de 50%, 75% e 90% para cada propriedade para todas as células.

### **3.6.2. Clusterização K-Means de células.**

Dado que o objetivo da definição de valores de corte é delimitar áreas do reservatório que representem maior viabilidade de produtividade, a separação de partes do reservatório (neste caso, as células) em viáveis ou não se trata de um problema de classificação discreta. Assim, é possível diminuir o fator de subjetividade na definição de valores de corte pela clusterização das células do modelo em diferentes classes baseadas nos valores modelados para cada propriedade.

Tendo em mente que o método K-Means é escalável para grandes bases de dados e produz resultados esféricos condizentes com o princípio geoestatístico de correlação entre variância e distância entre amostras (Romary et al, 2012), além de ser comumente usados para classificação de dados de reservatório em diferentes eletrofácies (Schlumberger, 2015), utiliza-se do método para separação das células em diferentes classes. No entanto, técnicas de redução de dimensionalidade como Mapas Auto Organizáveis (Self Organizing Maps – SOM) aplicadas à dados petrofísicos antes da aplicação de técnicas de clusterização tradicionais como o K-Means possibilitam melhor classificação das rochas em diferentes classes (Kuroda et al., 2012).

O método de clusterização K-Means é um método de classificação não supervisionado que classifica os dados de entrada em K diferentes classes. O método K-Means trata-se de um método iterativo, inicialmente escolhendo K pontos aleatórios dentro do domínio dos dados (sendo K o número de classes) e designando uma classe a cada ponto de acordo com a menor distância euclidiana do ponto aos centroides. Estes pontos aleatórios são tidos como os centroides iniciais de cada classe e tem sua posição iterativamente atualizada tentando maximizar a distância entre os centroides e minimizar a variância entre os pontos pertencentes à mesma classe (Lloyd, 1982).

Matematicamente, o algoritmo do K-Means é definido por uma etapa inicial de atribuição de classes a cada ponto equivalente à construção de um Diagrama de Voronoi utilizando os centroides iniciais como pontos de referência, tal que, para cada amostra  $x$  num conjunto  $\{x_1, x_2, \dots, x_n\}$ :

$$S_i = \begin{cases} 1, & \text{se } r = \arg \min \sum_{i=1}^k d(c_i, x) \\ 0, & \text{caso contrário} \end{cases} \quad (3.6.3.1)$$

Tal que a resposta para cada  $x$  é um vetor  $V$  de comprimento  $k$ :

$$V = \{S_1, S_2, \dots, S_k\} \quad (3.6.3.2)$$

E a classe  $C$  assinalada a cada ponto se dá na forma:

$$C_x = j ; v_j = \arg \max V ; j = \{1, 2, \dots, k\} \quad (3.6.3.3)$$

$S_i$  representa uma variável booleana indicando se cada ponto pertence a cada classe  $k$ .  $k$  é o número de classes e  $d(c_i, x)$  representa a distância euclidiana entre elemento  $x$  e cada  $i$ -ésimo centroide  $c_i$ . Como  $V$  é um vetor com  $k-1$  elementos 0 e apenas um único elemento 1, a posição do elemento 1 será a classe assinalada à amostra  $x$ . Em seguida, a posição de cada centroide é atualizada e, para cada classe, o novo centroide é posicionado na posição média de todos os pontos pertencentes à aquela classe. Estas duas etapas são repetidas iterativamente até que nenhum ponto

troque de classe entre duas iterações, momento em qual o algoritmo é considerado como convergente, ou até que se alcance um número máximo de iterações pré-definido.

O método de Mapas Auto Organizáveis é um método de redução de dimensionalidade via aprendizado de máquina não supervisionado baseado em redes neurais artificiais capaz de converter relações estatísticas complexas e não lineares de alta dimensionalidade em simples relações geométricas de baixas dimensões (Matos et al., 2004; Leite & Filho, 2010). Dado isto, pode ser interpretado que dados próximos no espaço de entrada terão representações próximas no espaço de saída do algoritmo (Kuroda et al, 2012).

Como trata-se de um algoritmo de aprendizado competitivo, no qual apenas uma unidade do espaço de saída fornece resposta a um sinal de entrada (Gonçalves et al, 1996). A estrutura do algoritmo é composta por duas camadas: uma de entrada e outra de saída. Na camada de entrada cada uma das mais de 450 mil células do modelo é um vetor de tamanho igual ao número de propriedades modeladas, cada uma correspondendo a uma dimensão no conjunto (Kuroda et al, 2012). Na camada de saída, cada neurônio é composto por um vetor de tamanho igual aos vetores de entrada, representando pesos para cada neurônio para cada variável (neste caso, as propriedades modeladas).

Os pesos tem inicialmente valores obtidos das duas primeiras componentes principais obtidas do conjunto de entrada e são atualizadas ao longo do processo de treinamento e convergem para valores melhores adaptados independentemente de seus valores originais (Stundner & Oberwinkler, 2004). A função que determina qual neurônio é a única resposta de cada vetor de entrada (mas não a resposta para apenas uma entrada) é a distância euclidiana entre as entradas e saída. Ou seja, para cada entrada, é atribuída a saída mais próxima. De forma iterativa, cada saída é movida em direção aos vetores de entrada de qual ela é resposta, afetando também as saídas dentro de sua vizinhança (Kuroda et al, 2012).

Assim, para este estudo, é definida uma matriz de tamanho de 58x58 neurônios, totalizando 3.364 neurônios, tamanho escolhido de acordo com o valor sugerido por Vesanto & Alhoniemi (2000) dado que:

(3.6.3.4)

$$m = 5 * \sqrt{n}$$

Onde  $m$  é o tamanho da matriz ( $m=3.364$ ) e  $n$  é o número de amostras ( $n = 452.668$ ) de entrada. Obtida a matriz de saídas para cada variável de entrada, são utilizados métodos de clusterização para a separação dos dados em classes e as classes em que cada neurônio é classificado são passadas de volta à suas respectivas entradas.

A escolha do número de classes para classificação dos dados permanece como principal fonte de subjetividade no método. Busca-se ao mesmo maximizar a variância entre as diferentes classes e ao mesmo tempo minimizar a variância dentro de cada classe. Quanto maior o número de classes, menor será a variância intra-classe de cada classe e maior será a variância inter-classe, no entanto, quanto maior o número de classes, menos significativa é a classificação obtida. Por exemplo, com  $N$  amostras, ao considerarmos  $N$  classes, a variância intra-classe é 0 e a variância inter-classe é a variância total da amostra, mas um modelo com  $N$  classes não introduz qualquer informação nova. Pode-se reduzir a subjetividade desta medida ao se computar o algoritmo com diferentes valores de  $K$  e registrar os valores em cada iteração para os índices de Davies-Bouldin e de silhueta. O índice de Davies-Bouldin tem como parâmetros a relação inversa entre a distância entre os centroides de cada classe e a variância interna de cada classe, assim, para valores menores que 1, o índice representa boa separação entre as classes (Kuroda et al, 2012). O índice de silhueta é uma média da relação para cada ponto da distância entre o ponto e os pontos de outras classes e a distância entre o ponto e os pontos de sua mesma classe, assim, quanto maior o índice de silhueta de um classificador, melhor os pontos estão representados dentro de suas classes.

Para aplicação dos métodos aos dados modelados, inicialmente foi desenvolvida uma função em Python para conversão dos dados para cada propriedade do formato nativo do software Schlumberger Petrel .grdecl para arrays da biblioteca NumPy e convertidos para tabelas .csv com a utilização da biblioteca Pandas. O código desta função encontra-se disponível no Anexo 1 e utiliza as bibliotecas open source Pandas (McKinney, 2010), NumPy (Oliphant, 2006; van der Walt et al., 2011) para converter os arquivos.

A aplicação dos métodos K-Means e SOM aos dados convertidos também foram feitas utilizando scripts em Python, utilizando as bibliotecas citadas anteriormente e também a biblioteca Scikit-Learn (Pedregosa et al., 2011) e MiniSOM, fonte dos algoritmos de K-Means e SOM respectivamente utilizados. Utiliza-se também as bibliotecas Matplotlib (Hunter, 2007) e Seaborn para visualizações.

Em seguida, toma-se a classificação discreta das células em diferentes classes como uma medida booleana de N/G, com células pertencentes à classe de maiores porosidades e menores saturações de água médias consideradas com N/G de 1, e células pertencentes às demais classes com N/G de 0. Ao mesmo tempo, calcula-se também o volume das células de cada classe, possibilitando a utilização de outras classes com N/G em 1.

### **3.6.3. Classificação por modelo de mistura gaussiana.**

Embora o método K-Means ofereça uma classificação satisfatória das células em diferentes classes, o K-Means ainda tem a limitação de oferecer classificações discretas para um número pré-determinado de classes, portando, seu uso na estimação de N/G é limitado a valores booleanos.

Outra limitação do K-Means, diretamente relacionada à sua natureza discreta, é a capacidade do algoritmo de classificar de maneira satisfatória pontos de natureza ambígua (Raykov et al., 2016), ou seja, para pontos próximos a fronteira de 2 classes, embora o K-Means consiga determinar qual o centroide mais próximo, o algoritmo não fornece qualquer tipo de informação sobre os outros centroides.

Modelos de mistura gaussiana (Gaussian Mixture Models – GMM), embora caracterizados por funções de densidade de probabilidades de diferentes subpopulações dentro de uma maior população, podem ser utilizados como modelos de classificação com usos similares ao K-Means. Considerando K classes numa distribuição de valores como K subpopulações dentro do conjunto de valores, é possível utilizar o GMM para obter a função de densidade de probabilidade de cada

classe e, conseqüentemente, a probabilidade de cada ponto pertencer a cada classe. Em seguida, classifica-se cada ponto de acordo com a classe de maior probabilidade. Assumindo que se conhece o número de classes ou subpopulações em uma distribuição, o GMM estima máxima verossimilhança por um algoritmo de máxima expectativa (VanderPlas, 2016).

Mantendo o número de classes observado no método K-Means, obtém-se pelo GMM uma nova classificação dos dados modelados. Assim como para o K-Means, inicialmente atribui-se razão N/G de 1 para os valores classificados para a classe de maior porosidade e menor saturação de água e também se calcula o volume de cada classe.

No entanto, por fornecer as probabilidades de cada ponto pertencer a cada classe, é possível estabelecer valores não booleanos para a razão N/G. Assim, calcula-se também HCPV considerando a probabilidade de cada ponto pertencer a classe de maior porosidade e menor saturação de água como a razão N/G da célula. De maneira similar, também se calcula HCPV tomando a razão N/G de cada célula como a probabilidade de o ponto em questão não pertencer a classe de menor porosidade e maior saturação de água.

## 4. RESULTADOS E DISCUSSÃO

Nesta seção do estudo os resultados obtidos dos métodos apresentados anteriormente são apresentados na mesma ordem em que os métodos são apresentados. Ao mesmo tempo, também acompanham estes resultados discussões sobre as informações geradas e seu impacto nas etapas seguintes.


### 4.1. Processamento Sísmico e Descontinuidades

A etapa de processamento de atributos sísmicos tem como resultado o volume de *ant-tracking* bem como a individualização de estruturas identificadas no volume de




*ant-tracking*. O volume de *ant-tracking* obtido mostra que discontinuidades ocorrem de maneira disseminada no volume sísmico analisado (Figura 15; Figura 16).

Individualizando as discontinuidades obtidas pelo método do *ant-tracking*, observa-se uma predominância de mergulhos sub-verticais a verticais com direção azimutal aproximadamente E-W (Figura 17). Filtrando as discontinuidades obtidas mantendo apenas discontinuidades com extensão mínima de 200 metros em qualquer direção se observa manutenção das tendências estruturais observadas (Figura 18).




**Figura 15 - Atributo de Ant-Tracking no crossline 1744. Refletor entre 2200m e 2400m de profundidade corresponde ao horizonte do topo do Quissamã. Refletor entre 2600m e 2800m de profundidade corresponde ao horizonte do topo do Lagoa Feia. Nota-se a ocorrência de forma disseminada de discontinuidades detectadas pelo fluxo de trabalho definido.**




**Figura 16 - Atributo de Ant-Tracking nos cortes em profundidade de 2300 e 2500m. 2300m sendo a profundidade aproximada do topo do Quissamã e 2500m a profundidade aproximada do contato óleo-água.**

Densidade de Estruturas - Todas as descontinuidades - 1950 amostras



**Figura 17 - Distribuição de descontinuidades para todas as descontinuidades. Estruturas predominantemente Leste-Oeste com mergulhos para Norte e Sul.**

Densidade de Estruturas - 200m de Extensão - 95 amostras



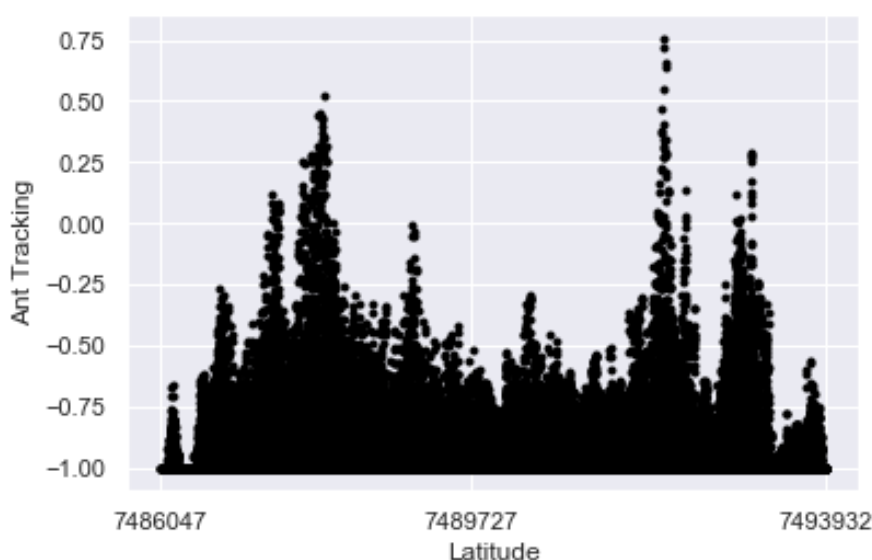
**Figura 18 - Distribuição de descontinuidades com mais de 200m de extensão em qualquer direção. Nota-se a manutenção da tendência estrutural observada para o conjunto de todas as descontinuidades.**

Franz, et al (1987) descreve o Campo B como inserido em uma anticlinal de eixo NE-SW localizada entre duas grandes falhas regionais paralelas ao eixo de dobra. Nota-se que a maior parte das descontinuidades identificadas na utilização do método de *ant-tracking* são superfícies perpendiculares ao eixo da anticlinal (Figura 17; Figura 18), fornecendo possível indicador de que o evento de dobramento originador da anticlinal não é também originador das falhas e fraturas do Campo B. Corroborando assim com a teoria para a evolução estrutural de reservatórios da Bacia de Campos proposta por Franz (1987) onde são identificados ao menos dois estágios de fraturamento.

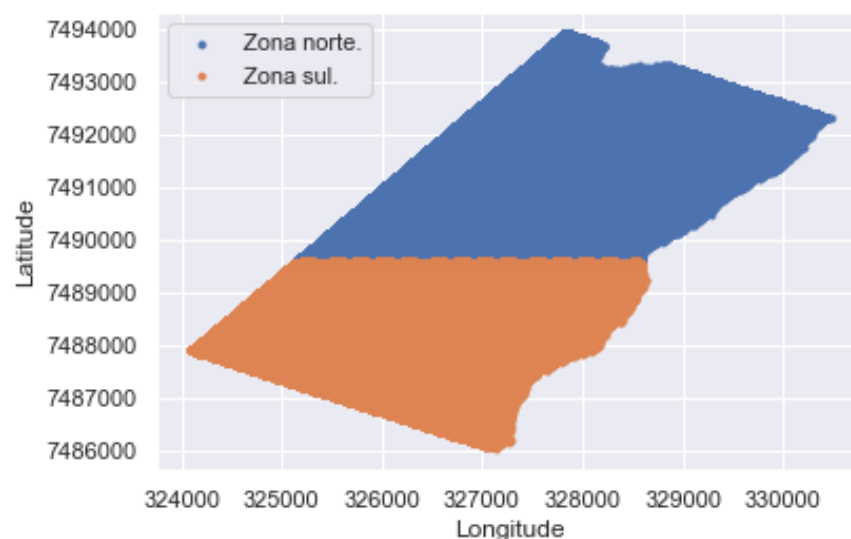
O estudo de Tomaso et al (2013) divide o Campo B em duas zonas distintas de acordo com intensidade de fraturamento, sendo estas uma zona sul mais fraturada e com microporosidade; e uma zona norte, com porosidade primária e pouco fraturada. Considerando esta divisão e assumindo o Ant-Tracking como uma medida do grau de fraturamento da rocha, observa-se a variação dos valores de Ant-Tracking de acordo com a posição de cada célula (Figura 19). Também se separa o reservatório em zona

sul e zona norte utilizando a mediana das coordenadas como fronteira (Figura 20) e observando os valores de Ant-Tracking nas 2 zonas (Tabela 5; Figura 21).

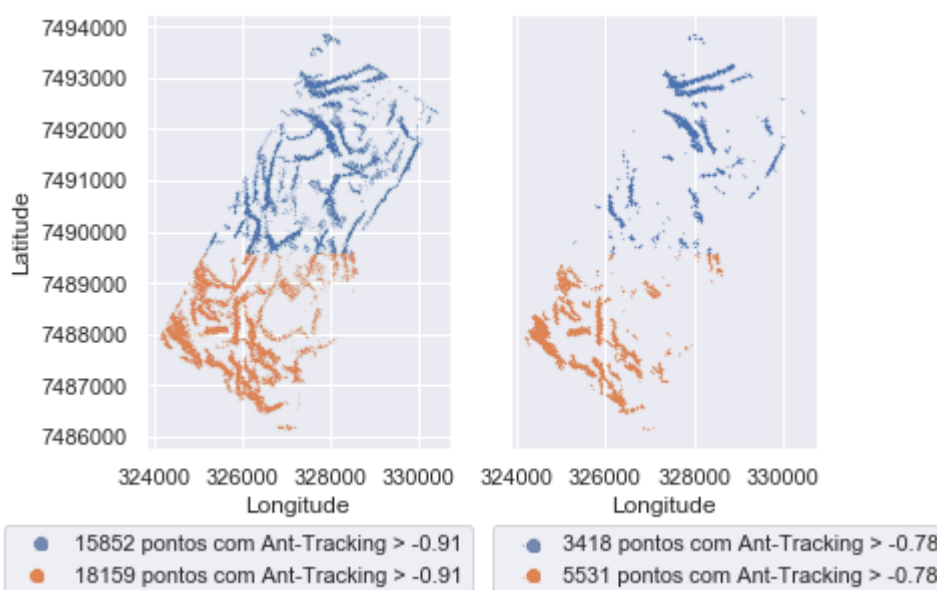
Não é possível identificar uma relação entre a variação de valores de Ant-Tracking e Latitudes e tão pouco é possível observar valores de Ant-Tracking suficientemente maiores em média na Zona Sul em relação à outras zonas (Figura 19; Tabela 5). No entanto, o maior número de células com elevados valores de Ant-Tracking na Zona Sul (Figura 21; Figura 22) bem como a maior porcentagem de suas células se apresentarem com valores elevados de Ant-Tracking (Tabela 6; Tabela 7) fornece certa evidência para a divisão observada por Tomaso et al. (2013).



**Figura 19 - Variação de Ant-Tracking com Latitude. Não se observa tendência clara na distribuição entre as duas variáveis. Cada ponto no gráfico corresponde à uma célula no modelo. Consideradas apenas células dentro do reservatório (Entre Quissamã e contato óleo-água).**



**Figura 20 - Delimitação de Zonas Norte e Sul do reservatório, cada uma com 234.109 células.**  
**Fronteira entre as zonas encontra-se deslocada para o sul devido à maior espessura do reservatório na Zona Sul. Cada ponto no gráfico corresponde à uma célula no modelo. Pontos plotados independentemente de sua posição vertical. Consideradas apenas células dentro do reservatório (Entre Quissamã e contato óleo-água).**



**Figura 21 - Distribuição no espaço para os pontos de altos valores de Ant-Tracking. -0.91 corresponde ao valor médio de Ant-Tracking no reservatório adicionado ao valor do desvio padrão de Ant-Tracking no reservatório, -0.78 representa o valor médio somado a três vezes o desvio padrão. Nota-se a maior frequência com que estes pontos ocorrem na zona sul em relação à zona norte. Cada ponto no gráfico corresponde à uma célula no modelo. Pontos plotados independentemente de sua posição vertical. Consideradas apenas células dentro do reservatório (Entre Quissamã e contato óleo-água).**

**Tabela 5 - Distribuição dos valores de Ant-Tracking nas diferentes Zonas do volume sísmico. Embora a Zona Sul mostre um valor média de Ant-Tracking superior tanto à Zona Norte quanto a região não reservatório do Quissamã, a diferença observada na média é menor do que o desvio padrão destas medidas.**

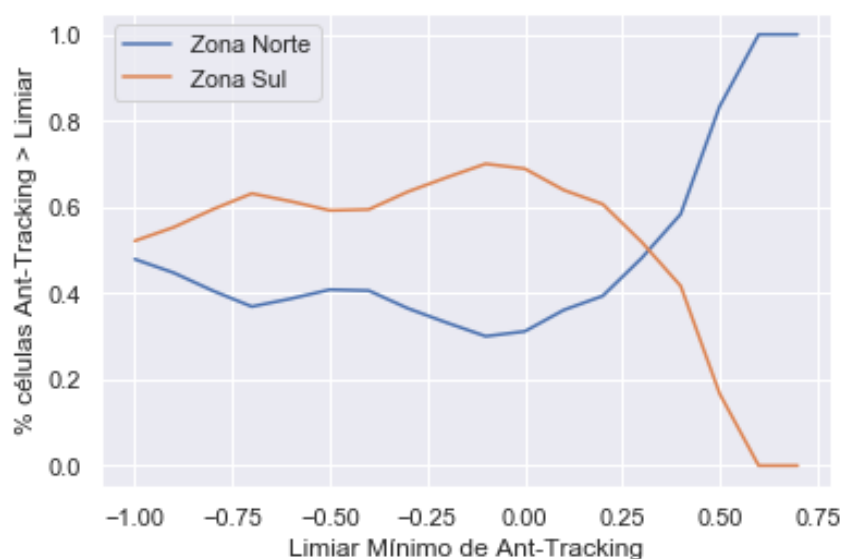
Zona	N células	Ant-Tracking		
		Média	Desvio Padrão	Mín Max
Norte	234079	-0.9808	0.0612	-1 0.76
Sul	234140	-0.9770	0.0735	-1 0.52
Reservatório	468219	-0.9789	0.0676	-1 0.76
Quissamã	1692162	-0.9791	0.0622	-1 0.76
Não Reservatório	1223943	-0.9792	0.0600	-1 0.41

**Tabela 6 – Número de células por zona com valores de Ant-Tracking superiores a -0.91. O valor de -0.91 corresponde ao valor médio de Ant-Tracking na região sobre o contato óleo-água dentro da Formação Quissamã adicionado ao desvio padrão do valor de Ant-Tracking nesta mesma região.**

Zona	N células com Ant-Tracking > -0.91	% do Total de Células
Norte	15852	6.772072676
Sul	18159	7.755616298
Reservatório	34011	7.263908556
Quissamã	126972	7.503536895
Não Reservatório	92961	7.59520664

**Tabela 7 - Número de células por zona com valores de Ant-Tracking superiores a -0.78. O valor de -0.78 corresponde ao valor médio de Ant-Tracking na região sobre o contato óleo-água dentro da Formação Quissamã adicionado à três vezes o desvio padrão do valor de Ant-Tracking nesta mesma região.**

Zona	N células com Ant-Tracking > -0.78	% do Total de Células
Norte	3418	1.46019079
Sul	5531	2.362261895
Reservatório	8949	1.911285104
Quissamã	29399	1.737363208
Não Reservatório	20450	1.670829442



**Figura 22 - Porcentagem de células localizadas na Zona Norte ou Sul para cada valor mínimo de Ant-Tracking (Limiar).** Nota-se que para Ant-Tracking de -1,0 os valores se distribuem igualmente entre as duas zonas, refletindo a separação das duas zonas pela Latitude mediana do reservatório. Para valores entre -0,8 e 0, valores que se correlacionam com elevadas intensidades de fraturamento, de 60% a 75% dos valores encontram-se na Zona Sul. Para os poucos ( $n = 151$ ) valores positivos de Ant-Tracking, estes concentram-se fortemente na Zona Norte. Assim indicando que as descontinuidades ocorrem de maneira mais disseminada pela Zona Sul enquanto concentram-se em uma área de alta descontinuidade na Zona Norte.

#### 4.2. Upscaling e Modelamento de Propriedades


Para avaliação dos resultados na etapa de upscaling e modelamento de propriedades são observadas as distribuições dos valores antes e após cada processo e avaliado se o processo desenvolvido honra de maneira satisfatória a distribuição original do dado.

As propriedades modeladas foram as propriedades de porosidade efetiva (PHIE), saturação de água (SW), densidade (RHOB), resistividade (ILD) e raio gama (GR). Para todas as propriedades, o método de upscaling foi o método de média móvel por camada como apresentado em 3.4, e o modelamento de propriedades se deu pela utilização do algoritmo de Função Gaussiana Aleatória de Simulação (*Gaussian Random Function Simulation* - GRFS) para as propriedades descritas por distribuições aproximadamente normais após upscaling e de Krigagem com Deriva Externa (KDE) para as propriedades em que não observa-se distribuição normal dos dados. Nota-se que apenas a propriedade de Saturação de Água não mostrou distribuição

aproximadamente normal após upscaling, sendo a única propriedade modelada por KDE (Figura 23).


O método de upscaling por médias móveis desenvolvido apresenta bons resultados, honrando de maneira geral os dados de log de poço, em especial para os dados de porosidade efetiva (Figura 24) e densidade (Figura 26), apenas subestimando alguns picos locais para valores intermediários de resistividade e raio gama (Figura 25; Figura 27). Nota-se que os dados de porosidade e densidade apresentam distribuições mais simétricas que as distribuições de resistividade e raio gama, podendo ser a origem da diferença de precisão do método de upscaling para as diferentes distribuições.

Ao mesmo tempo, o algoritmo de Simulação Gaussiana (GRFS), como esperado, mostrou melhor desempenho ao tentar honrar as distribuições de entrada quando comparado ao algoritmo de Krigagem com Deriva Externa (KDE).




**Figura 23 - Distribuição de dados de Saturação de Água. Dados após upscaling honram bem os dados de poço. Modelagem por KDE tem como efeito a possível superestimação de valores medianos de saturação e suprimindo valores de baixa saturação. Efeitos do modelamento indicam que os cálculos de volume possam acabar subestimando o volume de hidrocarbonetos HCPV.**






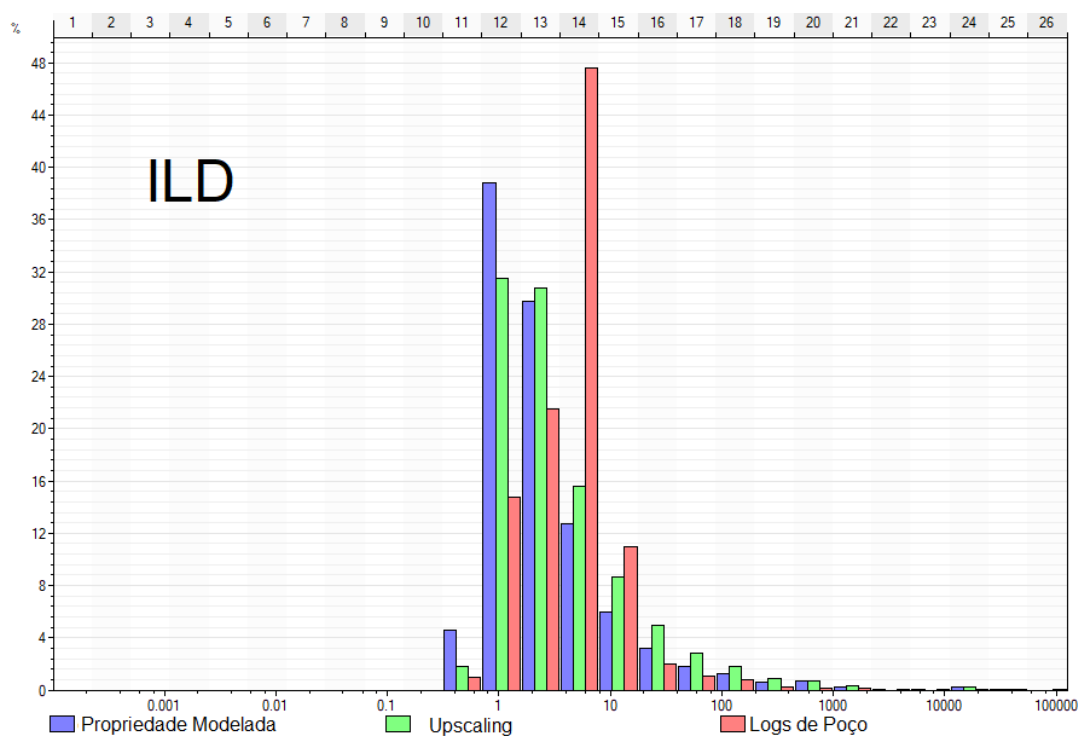
**Figura 24 - Distribuição de dados de Porosidade Efetiva. Dados de upscaling e modelados por GRFS honram de maneira satisfatória seus dados de input. Resultando num modelo confiável para a distribuição de valores de porosidade ao longo do reservatório.**



**Figura 25 – Distribuição de dados de raio gama. Embora o algoritmo de GRFS tenha honrado de maneira satisfatória a distribuição dos dados após upscaling, o método de upscaling acaba por subestimar valores de baixo GR entre 30 e 40 gAPI.**



**Figura 26 – Distribuição de dados de densidade. Assim como para dados de porosidade efetiva, tanto o algoritmo de GRFS quanto o método de upscaling honram seus dados de input.**



**Figura 27 – Distribuição de dados de resistividade. Assim como para os dados de raio gama, o algoritmo de GRFS honra de maneira satisfatória os dados de upscaling, enquanto o método de upscaling acaba por subestimar valores intermediários entre 5 e 10 ohm.m**

Os dados modelados são apresentados com seções paralelas à direção dos *crosslines*, cortadas para a zona do reservatório (sobre o contato óleo-água) dividindo o reservatório em dois volumes de mesmo tamanho para as visualizações horizontais. Para as visualizações verticais, os dados apresentados correspondem aos dados na superfície do topo da Formação Quissamã.

O modelo de saturação de água (Figura 28) tem medidas distribuídas de forma similar ao longo dos valores modelados, exceto pelo pico para valores de aproximadamente 60% observados na distribuição dos dados (Figura 23). O Modelo de saturação de água também apresenta uma transição suave de valores devido à utilização do algoritmo de KDE no modelamento. Também se observa valores de saturação de água menores na zona sul (média de 53%) quando comparados aos valores na Zona Norte (média de 62%). Os altos valores para a porção não reservatório do Quissamã (média de 73%) são esperados e fornecem evidência de uma correta determinação do contato óleo-água. Os valores mais altos observados mais próximos do contato óleo-água e do topo da Formação Quissamã também mostram a delimitação das fronteiras do reservatório.

**Tabela 8 - Valores estatísticos para a distribuição dos valores modelados. CV é o coeficiente de variação.**

Zona	SW Média	SW CV	PHIE Média	PHIE CV	GR Média	GR CV	RHOB Média	RHOB CV	ILD Média	ILD CV
Norte	0.628	0.316	0.201	0.250	40.968	0.514	2391.063	0.034	118.809	12.819
Sul	0.534	0.363	0.194	0.251	44.517	0.586	2402.915	0.036	126.016	15.608
Reservatório	0.581	0.347	0.198	0.251	42.745	0.556	2396.995	0.035	122.416	14.371
Quissamã	0.688	0.256	0.190	0.272	32.947	0.629	2409.227	0.038	86.729	16.141
Não Reservatório	0.730	0.199	0.187	0.278	29.198	0.620	2413.906	0.039	73.078	16.898
Total	0.632	0.296	0.194	0.260	38.075	0.581	2402.821	0.036	105.409	15.167

Os modelos de porosidade efetiva, raio gamma, resistividade e densidade ocorrem com valores variando de forma consideravelmente mais abrupta (Figura 29; Figura 30; Figura 31; Figura 32). Este efeito se dá devido ao GRFS honrar variações locais em médias e variâncias dos dados, ao contrário das medidas estáticas do modelo de krigagem.

**Nota-se no modelo** de porosidade que não há grande variação nos valores médios de porosidade entre as diferentes zonas, com valores de aproximadamente 20% de porosidade para toda a área da Formação Quissamã. O modelo de porosidade mostra uma distribuição de valores mais altos (25% a 30%) em camadas horizontais em meio a valores de baixa porosidade (10% a 15%). Embora não seja possível inferir sobre a distribuição litológica das fácies da Formação Quissamã com base nestes dados, a ocorrência de lentes mais grossas em meio a material menor poroso explicaria a distribuição observada.


**Nota-se também que** nos locais de ocorrência de baixos valores de saturação de água também tendem a ser observados altos valores de porosidade. Tal comportamento é esperado visto que a porosidade é uma variável na equação de Archie utilizada para estimar as saturações, no entanto, a resistividade também é uma variável da equação de Archie, e enquanto é observada correlação de apenas -13% entre saturação e resistividade, é observada uma correlação de -50% entre saturação e porosidade (Tabela 9). Indicando que regiões mais porosas do reservatório não só possuem maior espaço poroso para acumulação de fluidos, mas que estes fluidos são compostos em menor parte por água.

**Tabela 9 – Valores de correlação entre as propriedades modeladas. Tabela tem valores repetidos omitidos.**

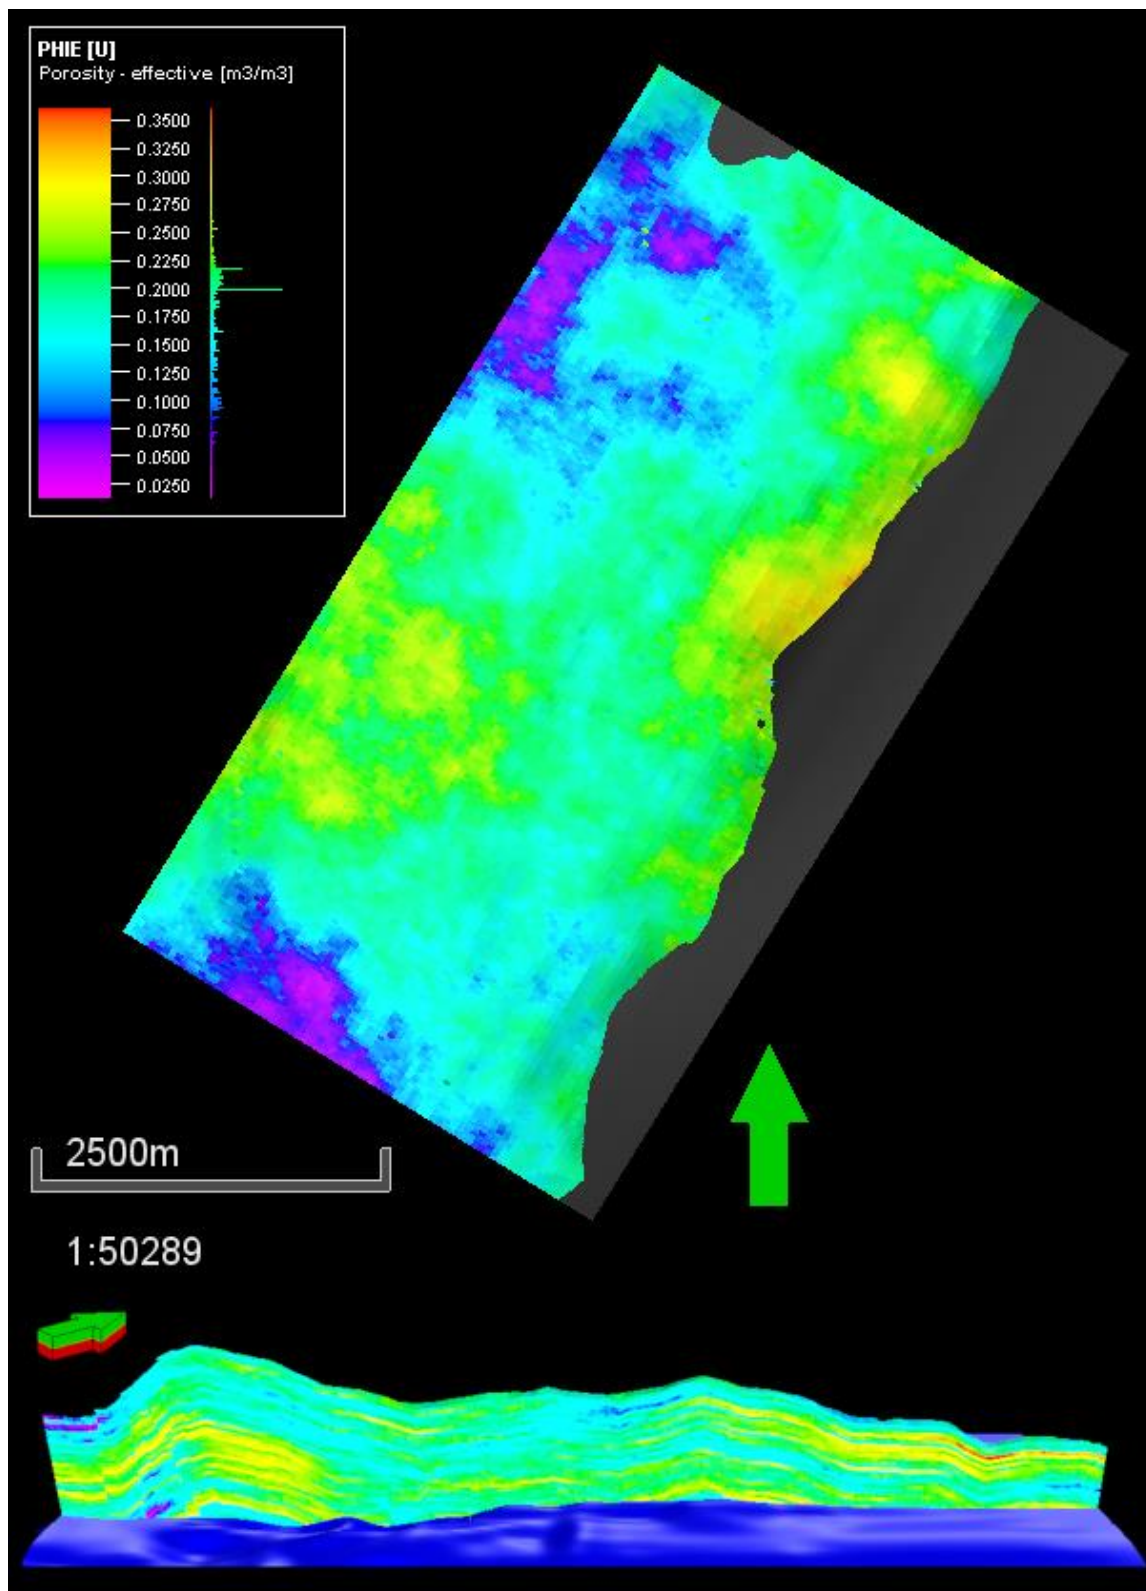
Valores de Correlação entre Propriedades					
	SW	PHIE	GR	ILD	RHOB
SW	1				
PHIE	-0.50388	1			
GR	0.265209	-0.17235	1		
ILD	-0.13204	0.061554	-0.04862	1	
RHOB	0.481628	-0.40022	0.069769	-0.06205	1

Adicionalmente, a observação do modelo de raio gama revela uma dependência significativa da profundidade com os valores modelados, com um aumento súbito de valores próximos ao topo do Quissamã indicando o início de uma possível transição de litologias.

Quanto aos modelos de resistividade e densidade, o modelo de resistividade apresenta valores muito elevados em seu CV devido ao predomínio de baixas resistividades por toda a área do modelo exceto pelos altíssimos picos associados aos locais de baixa saturação de água. Já o modelo de densidade mostra valores aproximadamente constantes em torno dos valores médios.

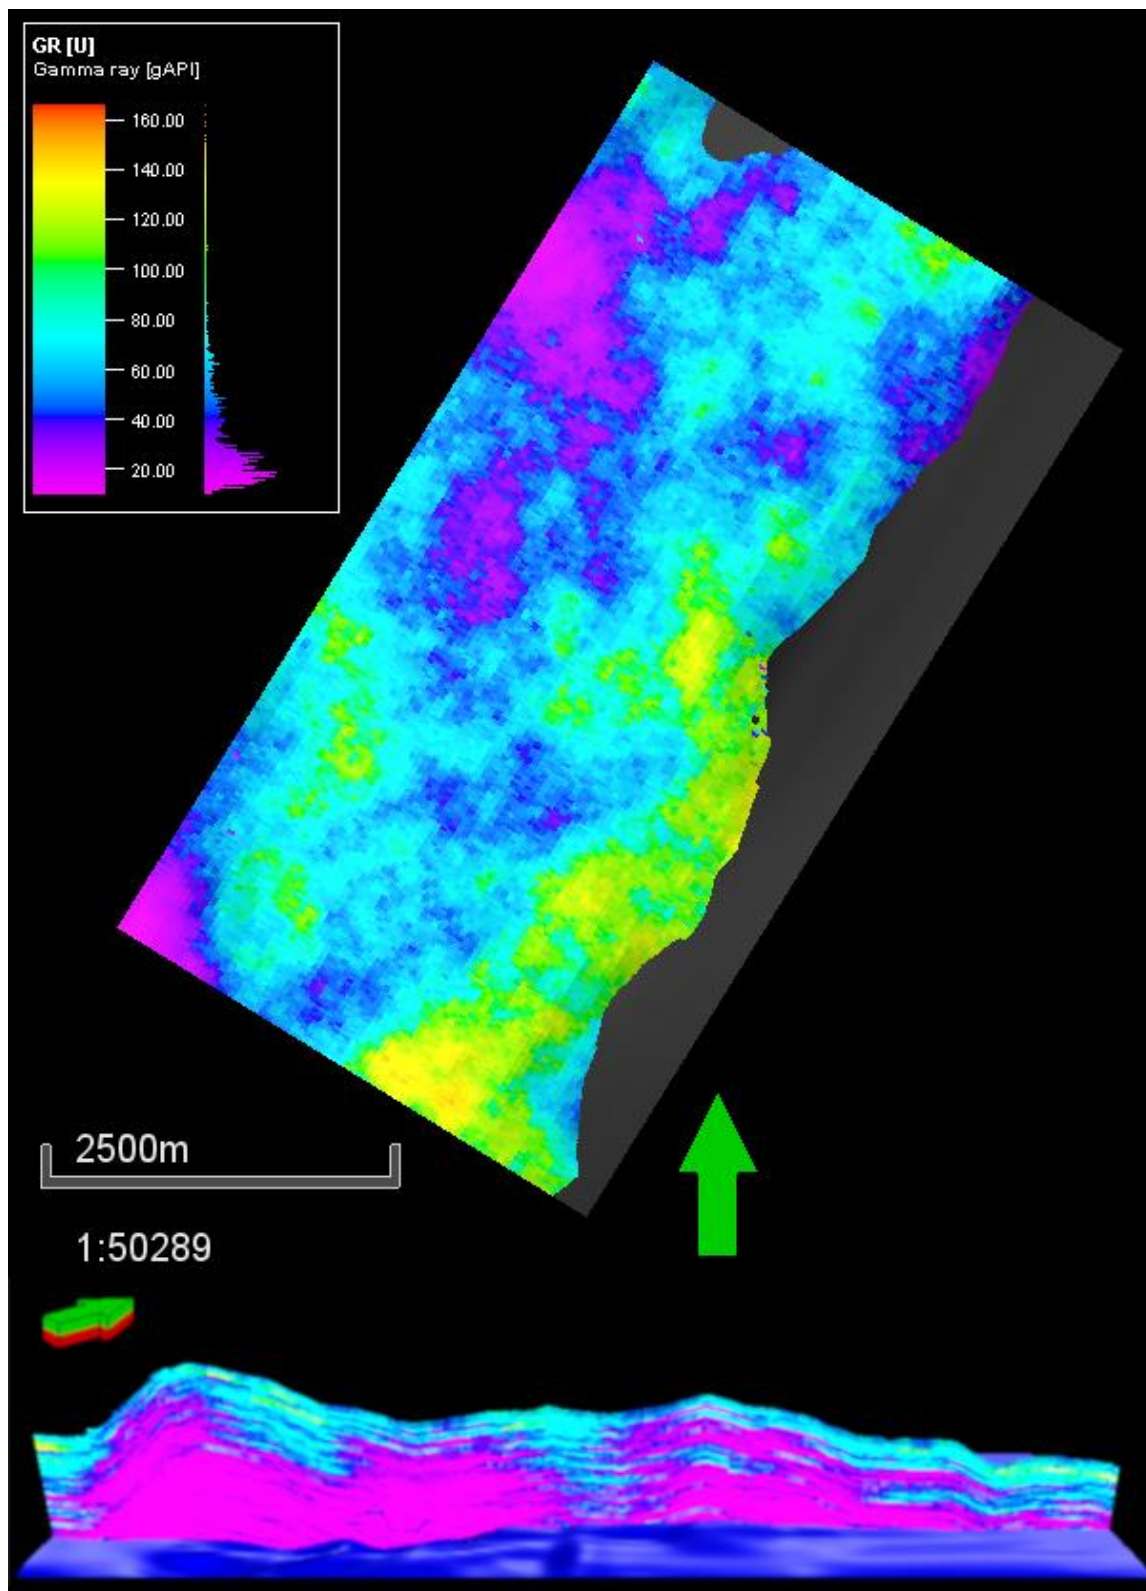


**Figura 28 – Modelo de saturação de água (SW). Valores distribuem-se de maneira similar para diferentes níveis de saturação de água. Algoritmo de KDE resulta em transições de valores suavizadas. Nota-se os maiores valores de saturação próximos ao topo e base do reservatório, evidenciando as regiões de fronteira do reservatório, assim como a presença de uma região na porção sudoeste do reservatório com valores muito baixos de saturação.**

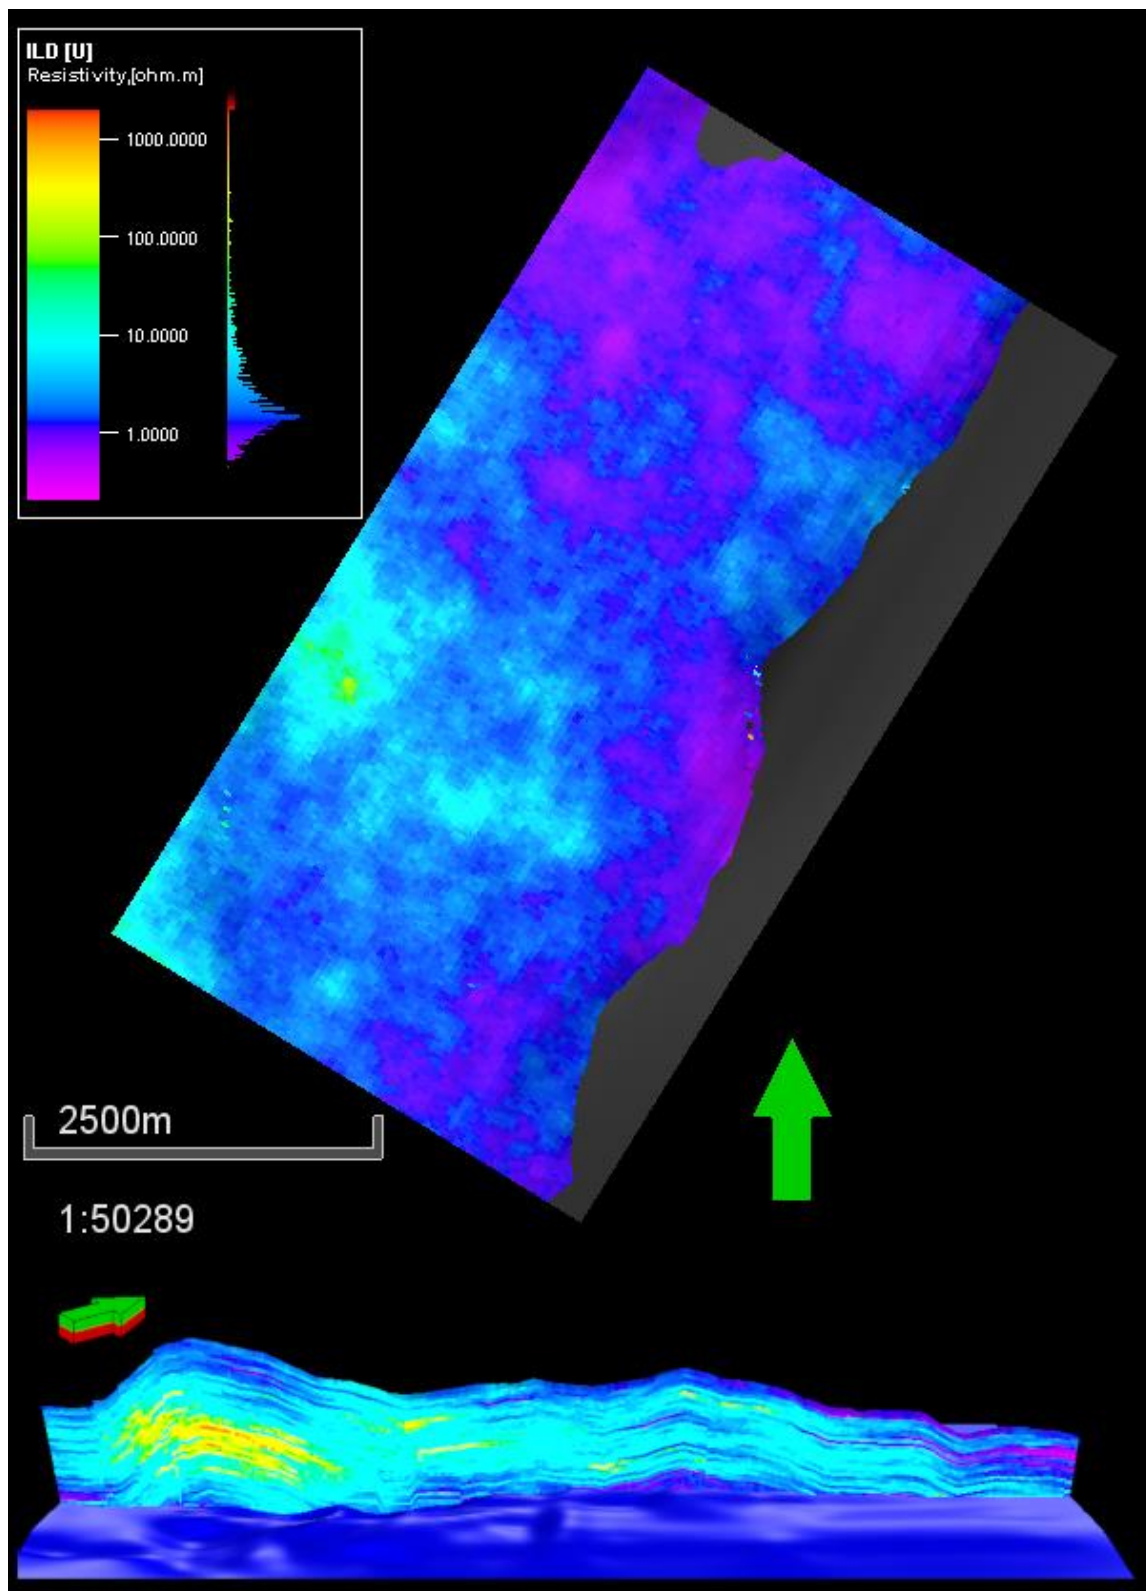


**Figura 29 - Modelo de porosidade efetiva (PHIE). Valores distribuídos em camadas horizontais contendo maiores valores. Observa-se associação entre maiores valores de porosidade nos mesmos locais onde ocorrem menores valores de saturação de água (SW).**



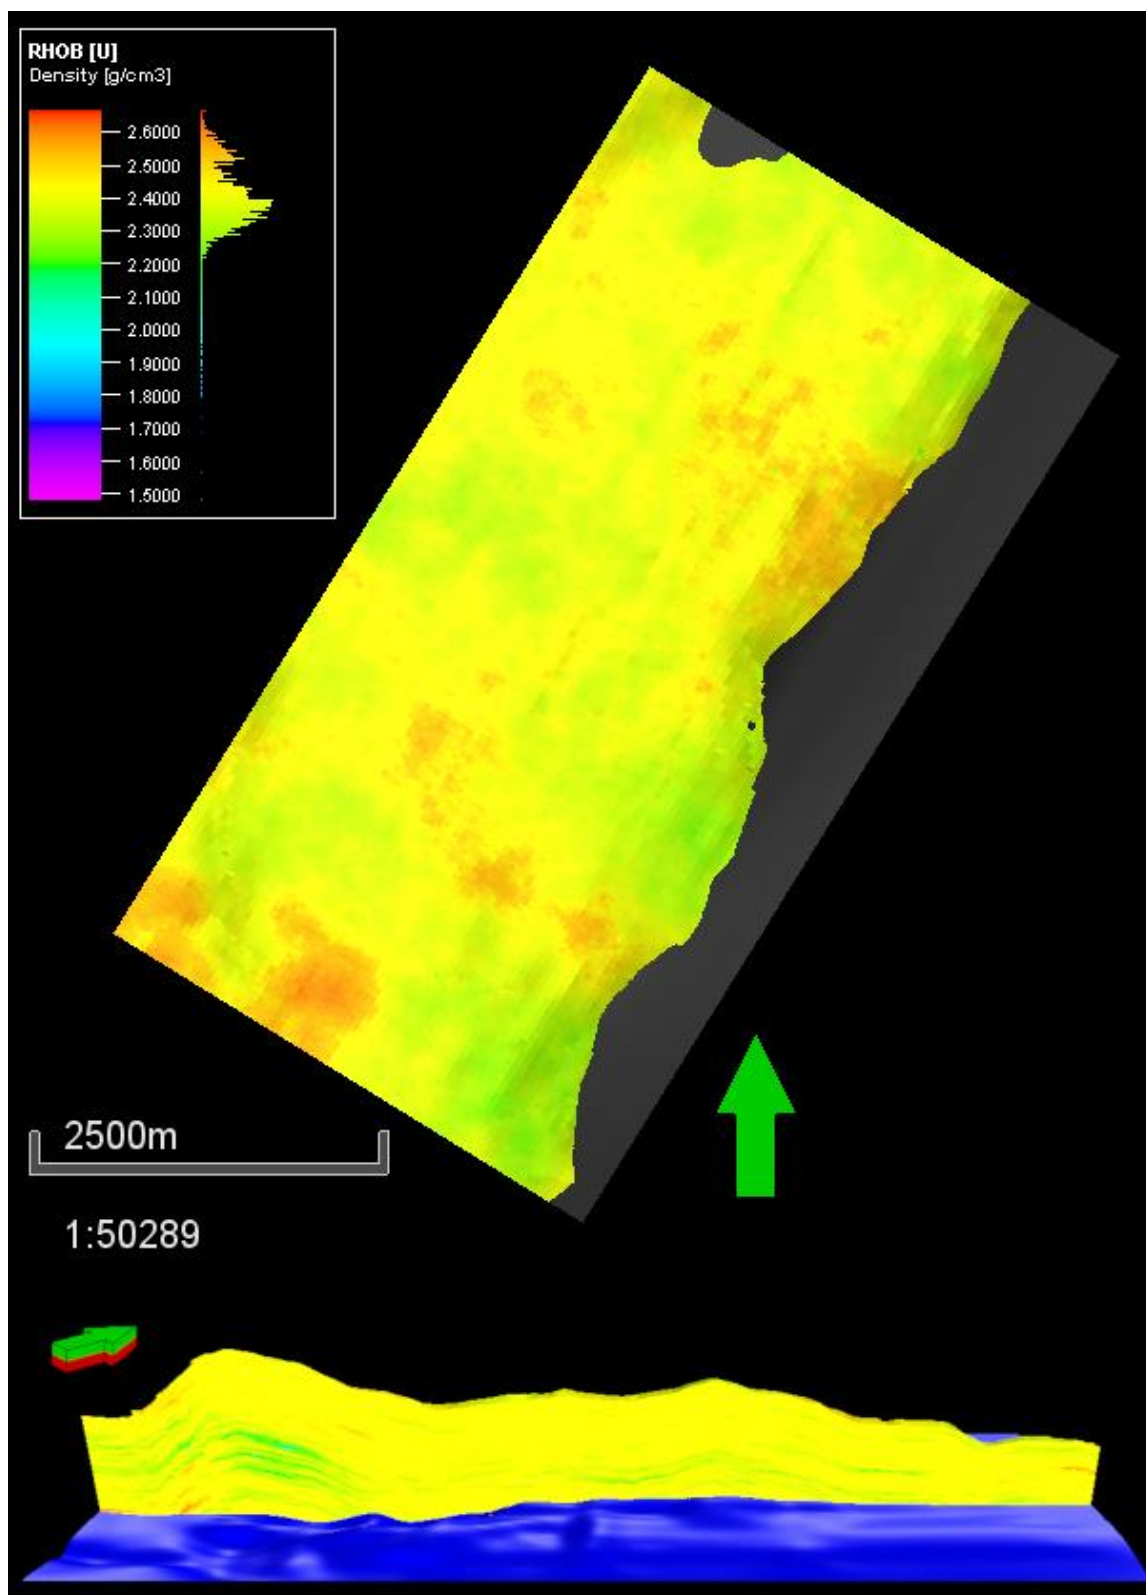


**Figura 30 - Modelo de raio gama (GR). Observa-se dependência entre os valores modelados e profundidade, com valores próximos ao topo da Formação Quissamã apresentando um aumento nos valores de raio gama observados.**




**Figura 31 – Modelo de resistividade (ILD). Observa-se predominância de valores baixos. A ocorrência de picos com valores bastante elevados na região sudoeste do modelo explica os altos valores de CV observados na Tabela 8.**






**Figura 32 – Modelo de Densidade (RHOB).** Valores aproximadamente constantes em torno da média de aproximadamente 2400g/cm<sup>3</sup> explicam baixos valores de CV observados na Tabela 8. Ao mesmo tempo, raras variações são observadas na região sudoeste, com quedas nos valores de Densidade associadas a valores de alta porosidade, alta resistividade e baixa saturação de água.

Refletindo os valores de correlação observados entre as propriedades modeladas de saturação de água e porosidade efetiva, a distribuição dos dados num plano mostra uma tendência entre os dois valores (Figura 33). O mesmo pode ser observado para os demais valores de correlação. Além disso, dados os valores constantes de resistividade e os baixos valores de CV para o modelo de densidade, observa-se a distribuição dos modelos de saturação, porosidade efetiva e raio gama de maneira conjunta (Figura 34). Sendo possível notar que os valores de raio gama distribuem-se de maneira aproximadamente independente dos valores de porosidade e saturação, o que reflete os valores de correção relativamente baixos para os pares.



**Figura 33 – Distribuições par a par das propriedades modeladas. Histogramas de distribuição das propriedades em casos em que a propriedade é comparada a ela mesma. Valores intermediários de correlação entre SW-PHIE e SW-RHOB observados na Tabela 9 podem ser visualizados. Nota-se ainda a distribuição concentrada em baixos valores observada para a propriedade de resistividade (ILD).**




**Figura 34 - Distribuição de valores modelados de saturação de água (SW), porosidade efetiva (PHIE) e raio gamma (GR). Observam-se os baixos valores de correção de GR com as demais propriedades detalhadas na Tabela 9.**

#### 4.3. Classificação de Reservatório

Com os dados modelados, busca-se a separação dos dados em diferentes agrupamentos de características semelhantes. Os resultados do algoritmo de mapas auto organizáveis permitem reduzir a dimensionalidade do problema de 5 (SW, PHIE, GR, RHOB e ILD) para 2 dimensões, observa-se a resposta dos neurônios do mapa gerado para cada variável de entrada e também a matriz correspondente às distâncias entre cada uma das respostas (Figura 35).


Nota-se que os neurônios com pesos mais altos para medidas de porosidade também concentram respostas menos intensas para medidas de saturação de água e densidade. Comportamento observado anteriormente nas propriedades modeladas. Ao mesmo tempo, devido a distribuição concentrada dos picos de alta resistividade, observa-se que os neurônios com alta resposta de resistividade ocorrem também de maneira concentrada, mostrando relação inversa com as respostas de saturação de água, comportamento esperado em uma rocha reservatório. Ao mesmo tempo, a observação da matriz de distâncias não revela um agrupamento óbvio dos dados,

ainda que os valores mais altos centrais cercados por diferentes zonas periféricas de baixos valores sugiram que existe um agrupamento das respostas da matriz de distâncias.




**Figura 35 – Matriz de Distâncias e respostas à cada variável do algoritmo de mapas auto organizáveis (SOM). Observa-se a relação entre altas respostas de porosidade e resistividade com baixas respostas de saturação de água e densidade.**

Computando o algoritmo de K-Means para valores de K entre 2 e 15 classes, são obtidos os respectivos índices de silhueta e Davies-Bouldin (Figura 36). O máximo local do índice de silhueta para um K de 3 classes acompanhado do mínimo local do índice de Davies-Bouldin para o mesmo valor de K representam forte evidência de que os dados na matriz de distância podem ser satisfatoriamente divididos em três classes diferentes.



**Figura 36 – Valores para os índices de silhueta e Davies-Bouldin computados para diferentes valores de K no algoritmo K-Means. O valor máximo para índice de silhueta e mínimo para Davies-Bouldin no valor de 3 classes indica provável separação dos dados em 3 diferente classes.**

Definido o número de classes para a classificação dos dados, computa-se novamente o algoritmo de K-Means com  $K=3$  e também se computa o algoritmo de GMM com 3 componentes (Figura 37). Observa-se a maior correspondência do algoritmo de GMM com a distribuição observada no mapa de distâncias, com a classe 0 correspondendo aos neurônios de maiores distâncias. Nota-se que o número da classe não é o mesmo entre os 2 algoritmos e depende da inicialização aleatória do algoritmo, não tendo qualquer significado além de separar os dados.



**Figura 37 – Classificações da matriz de distâncias. Valores entre 0 e 1 para o mapa de probabilidades de GMM são a probabilidade de cada neurônio pertencer a classe 2.**

Atribuindo a cada célula do grid do modelo as classes e probabilidades geradas pelos algoritmos de K-Means e GMM correspondentes ao neurônio que atua como resposta desta célula na camada de saída do mapa auto organizável, é possível mapear a distribuição entre classes entre os valores das propriedades. Chama-se aqui a classe de menor saturação de água e/ou maior porosidade como classe alvo, enquanto a classe contrária com maiores saturações e menor porosidade é chamada aqui como classe de descarte. Chama-se a classe entre os dois valores de classe intermediária.

Observa-se que o algoritmo de GMM conseguiu individualizar melhor as células pertencentes a classe alvo (Classe 1), mostrando maiores valores de porosidade (24%) e menores de saturação (35%) simultaneamente (Tabela 10), enquanto o K-Means obteve duas classes com porosidades semelhantes em torno de 21% (Classes 1 e 2) e uma classe (Classe 1) com a menor saturação de água em 46% (Tabela 11), definida como a classe alvo. Ao mesmo tempo, para os dois algoritmos observa-se a atribuição dos valores de alta resistividade à classe alvo, justificando os altos valores de resistividade média e coeficiente de variação observados na ocorrência dos picos de resistividade em células de muito baixa saturação de água (Figura 33; Figura 35).

Ao mesmo tempo, nota-se que o GMM classificou como alvo apenas 123,262 células quando comparado às 191,565 células alvo do K-Means. Considerando os valores similares de porosidade e saturação de água observados para as classes intermediária e descarte nos dois modelos, é provável que o K-Means tenha associado altos valores de raio gama à classe alvo. Classificando um grande número de células com alta resposta de raio gama e altas saturações de água como alvo. Tal efeito pode ser observado na classificação ainda no mapa auto organizável, tal que os neurônios com altas respostas para raio gama ocorrem na área superior esquerda e os com baixa resposta de saturação de água na área superior direita (Figura 35). Enquanto o K-Means coloca os neurônios de alta resposta em raio gama na mesma classe que os neurônios com baixa resposta em saturação, o GMM classifica os neurônios de alta resposta em raio gama de forma separada das baixas respostas em saturação (Figura 37).

**Tabela 10 - Distribuição estatística das propriedades modeladas entre as classes obtidas com o algoritmo de Modelo de Mistura Gaussiana, GMM.**

Classe	0	0	1	1	2	2
	Média	CV	Média	CV	Média	CV
SW	0.71	0.193	0.352	0.424	0.581	0.221
phie	0.164	0.268	0.239	0.132	0.215	0.14
GR	51.965	0.513	38.362	0.538	30.932	0.384
ILD	3.434	2.318	451.011	7.554	7.738	3.755
RHOB	2453.548	0.032	2322.954	0.02	2370.844	0.019
N	219425		123262		125532	

**Tabela 11 – Distribuição estatística das propriedades modeladas entre as classes obtidas com o algoritmo de K-Means.**

Classe	0	0	1	1	2	2
	Média	CV	Média	CV	Média	CV
SW	0.717	0.191	0.464	0.454	0.59	0.22
phie	0.162	0.275	0.215	0.214	0.218	0.15
GR	41.294	0.361	54.026	0.544	26.44	0.304
ILD	3.526	1.895	291.383	9.408	7.943	3.406
RHOB	2479.418	0.027	2347.234	0.025	2367.409	0.02
N	158179		191565		118475	

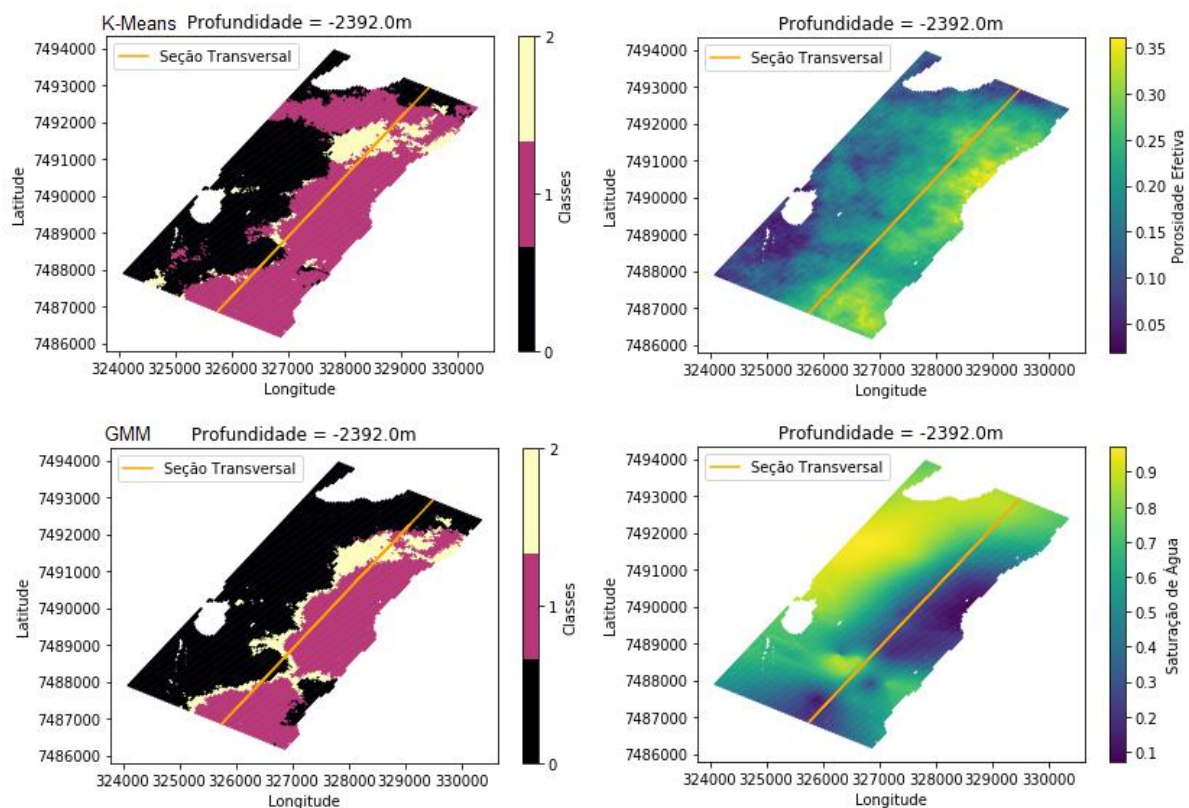
Observando a distribuição espacial da classificação para os dois algoritmos é possível observar que o K-Means classifica algumas regiões de porosidade intermediária e alta saturação de água como alvo (Figura 38). Este comportamento não é observado na classificação obtida do algoritmo de GMM. A classificação do GMM também resulta em uma transição melhor entre as classes alvo, intermediária e descarte, com células classificadas na classe intermediária geralmente circundando células classificadas como alvo. A distribuição observada no GMM é mais condizente com a provável distribuição de diferentes litologias no reservatório, ainda que a classificação leve em conta valores relativos ao conteúdo de fluidos do espaço poroso como resistividade e saturação de água.

Seções transversais dos mapas da Figura 38 apresentam o mesmo comportamento, com K-Means classificando zonas de alta saturação de água como alvo (Figura 39). Células classificadas como alvo também podem ser observadas circundadas por células classificadas como intermediárias.



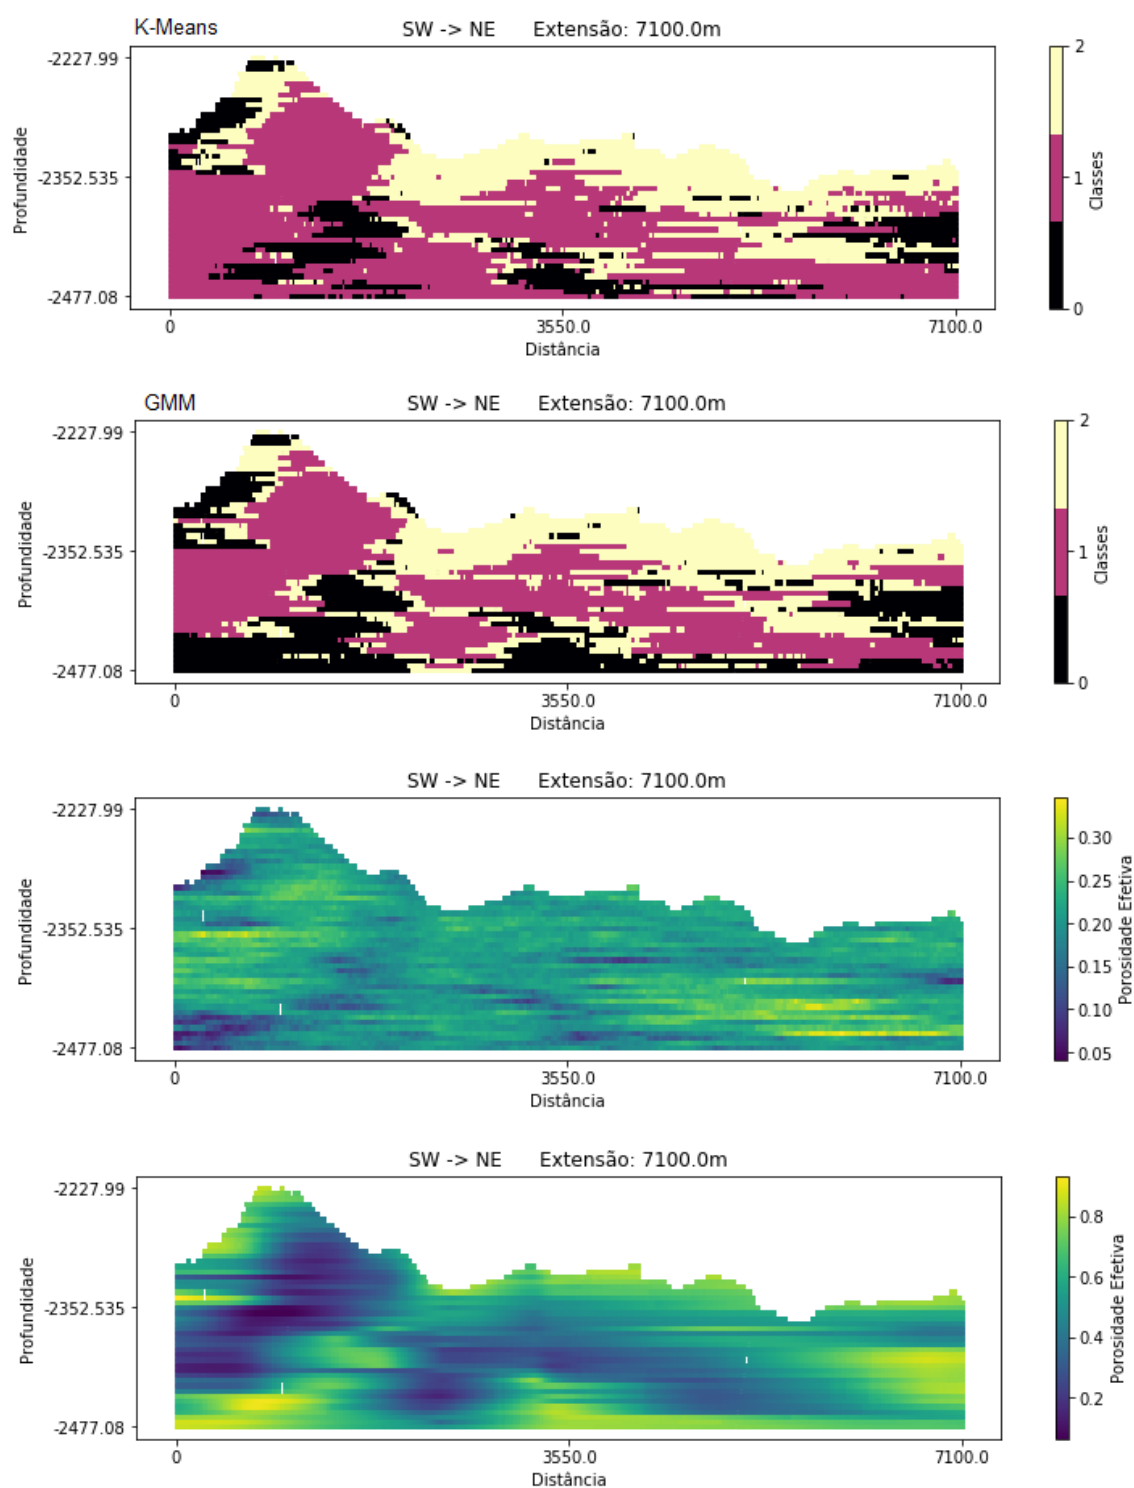
De forma adicional, os resultados da classificação obtida do algoritmo de GMM também tem respostas não discretas para a probabilidade de cada célula pertencer a cada classe obtidas da aplicação a cada célula das probabilidades correspondentes ao seu neurônio de resposta nos mapas auto organizáveis.

Assim, a observação da distribuição espacial das probabilidades de cada célula não pertencer a classe de descarte (ou, alternativamente, de cada célula pertencer a classe alvo ou intermediária) revela que o algoritmo de GMM classificou os neurônios da matriz de distâncias com um alto grau de certeza, visto que as probabilidades distribuem-se de maneira aproximadamente booleana em 1 ou 0 (Figura 40).

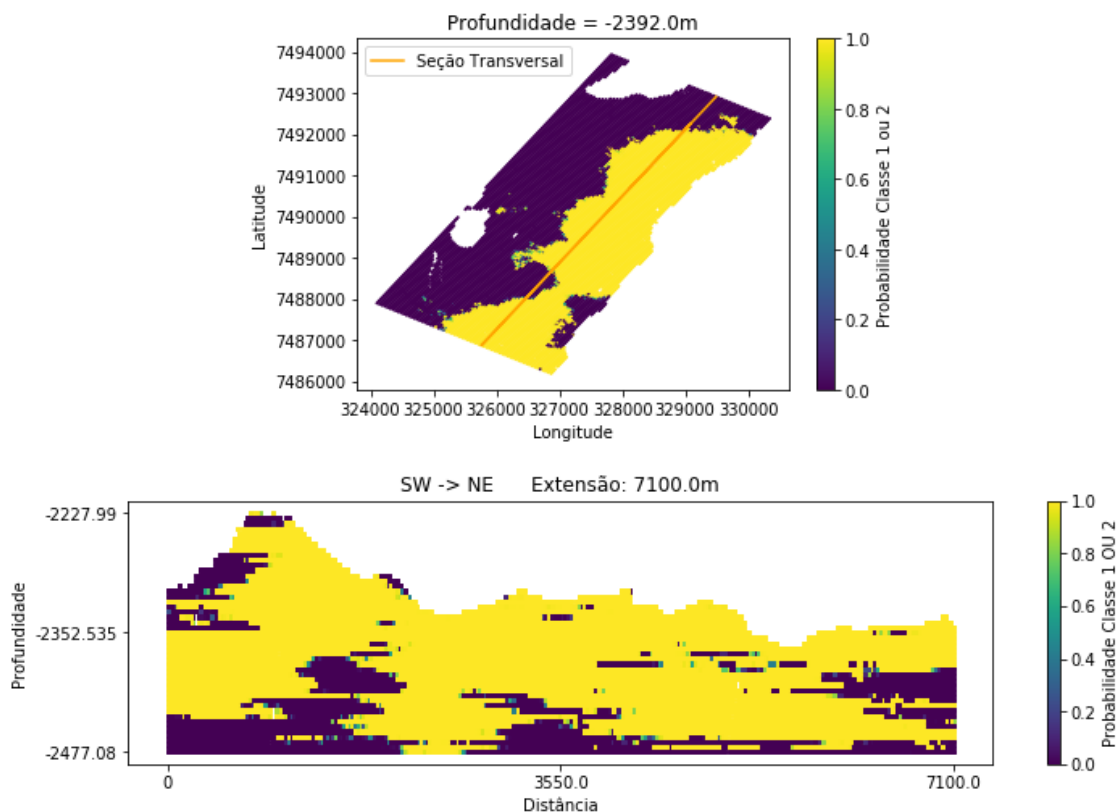


**Figura 38 – Mapas de distribuição das classificações para K-Means e GMM e propriedades de porosidade efetiva e saturação de água para profundidade de 2392m. Linha laranja indica as seções transversais da Figura 39.**





**Figura 39 - Seções transversais para as distribuições das classificações obtidas de K-Means e GMM. Seções correspondem as linhas indicadas nos mapas da Figura 38.**



**Figura 40 – Mapa e seção transversal de distribuição de probabilidades de cada célula pertencer a Classe 0 ou 1 na classificação obtida do método GMM.**

#### 4.4. Cálculos de Volume

Utilizando a equação 3.6.1. para o cálculo de volume poroso de hidrocarbonetos, pode-se definir diferentes casos de cálculos de volume com diferentes valores para os parâmetros da equação. Utilizando a mesma equação também são calculados os volumes presentes em cada classe obtidas dos classificadores K-Means e GMM, para cada classe, a equação utiliza N/G de 1 para células pertencentes à classe em questão e N/G de 0 para outras células (Tabela 12). O caso 0, ou controle trata-se do valor de volume atribuindo a cada célula o valor de N/G do ponto mais próximo nas classificações de net pay para poços do Campo B realizadas por Melani et al. (2015) e seus valores de porosidade e saturação de água correspondentes. Em seguida, são calculados diversos casos apresentados na Tabela 13 e seus resultados são comparados entre si e com o Caso 0 de controle na Tabela 14.

**Tabela 12 – Volumes obtidos para cada classe de acordo com os classificadores de K-Means e GMM. Os valores percentuais indicam a relação entre o volume referido e o obtido para a mesma classe do K-Means. Vb (Bulk Volume) é o volume total das células de cada classe, Vp (Pore Volume) o volume poroso enquanto HCPV (Hydrocarbon Pore Volume) é o volume de hidrocarbonetos.**

	Vb	Vp	HCPV	Vp - % K-Means	HCPV - % K-Means
K-Means Classe 0	4.9x10 <sup>8</sup>	8.0x10 <sup>7</sup>	5.7x10 <sup>7</sup>	100.00%	100.00%
K-Means Classe 1	5.9x10 <sup>8</sup>	1.2x10 <sup>8</sup>	5.6x10 <sup>7</sup>	100.00%	100.00%
K-Means Classe 2	3.7x10 <sup>8</sup>	8.0x10 <sup>7</sup>	4.7x10 <sup>7</sup>	100.00%	100.00%
GMM Classe 0	6.8x10 <sup>8</sup>	1.1x10 <sup>8</sup>	7.9x10 <sup>7</sup>	140.96%	139.38%
GMM Classe 1	3.8x10 <sup>8</sup>	9.2x10 <sup>7</sup>	3.2x10 <sup>7</sup>	71.57%	57.16%
GMM Classe 2	3.9x10 <sup>8</sup>	8.4x10 <sup>7</sup>	4.9x10 <sup>7</sup>	104.66%	103.74%
	rm <sup>3</sup>	rm <sup>3</sup>	rm <sup>3</sup>		

**Tabela 13 – Relação dos casos de cálculos de volume. Casos que trazem valores de Prop para saturação de água (SW) ou porosidade efetiva (PHIE) utilizam os valores modelados para cada célula para o cálculo. [1] O Caso 3 utiliza o valor constante de 0.581 para saturação de água, valor correspondente ao valor médio no reservatório. [2] O Caso 2 utiliza o valor constante de 0.198 para porosidade efetiva, valor corresponde ao valor médio no reservatório. [3] Valores de N/G de 0 ou 1 para cada célula baseados na classificação em poços de Melani et al. (2015), cada célula possui valor atribuído igual ao ponto mais próximo nos poços classificados. [4] Valores de corte baseados no percentil de 50% para ambas as propriedades. [5] Valores de corte baseados no percentil de 75% para ambas as propriedades. [6] Valores de corte baseados no percentil de 90% para ambas as propriedades.**

	SW	PHIE	N/G
Caso 0	Modelo	Modelo	Melani et al. (2015) [3]
Caso 1	Modelo	Modelo	1
Caso 2	Modelo	0.198 [2]	1
Caso 3	0.581 [1]	Modelo	1
Caso 4	Modelo	Modelo	N/G = 1 se: SW < 0.599 PHIE > 0.204 N/G = 0 caso contrário. [4]
Caso 5	Modelo	Modelo	N/G = 1 se: SW < 0.445 PHIE > 0.227 N/G = 0 caso contrário. [5]
Caso 6	Modelo	Modelo	N/G = 1 se: SW < 0.289 PHIE > 0.254 N/G = 0 caso contrário. [6]
Caso 7	Modelo	Modelo	K-Means: Classe 0: N/G = 0 Classe 1: N/G = 1 Classe 2: N/G = 1
Caso 8	Modelo	Modelo	GMM: Classe 0: N/G = 0 Classe 1: N/G = 1 Classe 2: N/G = 1
Caso 9	Modelo	Modelo	GMM: N/G = P'(0)

**Tabela 14 – Valores de volumes obtidos para cada caso descrito na Tabela 13. Vb (Bulk Volume) é o volume total das células de cada classe, Vp (Pore Volume) o volume poroso enquanto HCPV (Hydrocarbon Pore Volume) é o volume de hidrocarbonetos e tHCPV é o volume de hidrocarbonetos antes de aplicação das razões N/G. Valores percentuais indicam a variação de cada caso em relação ao Caso 0. Casos 7 e 8 apresentam valores de volume total (Vb) diferentes pois não incluem as células da Classe 0.**

Caso	Vb	Vp	tHCPV	HCPV	Vp - % Caso 0	tHCPV - % Caso 0	HCPV - % Caso 0
0	1.4x10 <sup>9</sup>	2.8x10 <sup>8</sup>	1.6x10 <sup>8</sup>	5.8x10 <sup>7</sup>	100.00%	100.00%	100.00%
1	1.4x10 <sup>9</sup>	2.8x10 <sup>8</sup>	1.6x10 <sup>8</sup>	1.6x10 <sup>8</sup>	100.00%	100.00%	275.13%
2	1.4x10 <sup>9</sup>	2.8x10 <sup>8</sup>	1.6x10 <sup>8</sup>	1.6x10 <sup>8</sup>	100.01%	104.60%	287.78%
3	1.4x10 <sup>9</sup>	2.8x10 <sup>8</sup>	1.6x10 <sup>8</sup>	1.6x10 <sup>8</sup>	100.00%	104.57%	287.71%
4	1.4x10 <sup>9</sup>	2.8x10 <sup>8</sup>	1.6x10 <sup>8</sup>	4.5x10 <sup>7</sup>	100.00%	100.00%	77.01%
5	1.4x10 <sup>9</sup>	2.8x10 <sup>8</sup>	1.6x10 <sup>8</sup>	1.3x10 <sup>7</sup>	100.00%	100.00%	22.47%
6	1.4x10 <sup>9</sup>	2.8x10 <sup>8</sup>	1.6x10 <sup>8</sup>	2.7x10 <sup>6</sup>	100.00%	100.00%	4.65%
7	9.7x10 <sup>8</sup>	2.0x10 <sup>8</sup>	1.0x10 <sup>8</sup>	1.0x10 <sup>8</sup>	72.32%	64.56%	177.63%
8	7.7x10 <sup>8</sup>	1.7x10 <sup>8</sup>	8.1x10 <sup>7</sup>	8.1x10 <sup>7</sup>	60.98%	50.61%	139.23%
9	1.4x10 <sup>9</sup>	2.8x10 <sup>8</sup>	1.6x10 <sup>8</sup>	8.1x10 <sup>7</sup>	100.00%	100.00%	139.02%
	rm <sup>3</sup>	rm <sup>3</sup>	rm <sup>3</sup>	rm <sup>3</sup>			

Seguindo o comportamento observado em 4.3., o K-Means estima maiores volumes na Classe 1 (alvo), ao mesmo tempo que estima menores volumes na Classe 0 (descarte). Da mesma forma, o Caso 7, calculado com base no K-Means, mostra maiores valores de Vp e HCPV quando comparado ao Caso 8, baseado no GMM. O Caso 9, baseado nas probabilidades de cada célula não pertencerem a Classe 0 no GMM mostra valor de HCPV similar ao obtido no Caso 8, indicando que a introdução de valores não booleanos para N/G não afetou significativamente os cálculos de volume. Isto se dá devido a maior parte das células terem probabilidades próximas a 0 ou 1 (Figura 40).

Nota-se também que com exceção dos Casos 4, 5 e 6, que utilizam os percentis dos valores das propriedades para definir valores de corte, todos os casos apresentam valores de HCPV consideravelmente maiores quando comparados ao Caso 0 baseado na aproximação das classificações de poço realizadas por Melani et al. (2015).

A comparação entre os valores obtidos nos Casos 1, 2 e 3, todos com N/G de 1, também traz informações a respeito do efeito da variação dos valores de porosidade efetiva e saturação de água nos cálculos de HCPV. Enquanto o Caso 1 utiliza os valores individuais de cada célula tanto para porosidade efetiva quanto para saturação de água, o Caso 2 atribui a cada célula o valor médio de porosidade efetiva no reservatório e o Caso 3 faz o mesmo para o valor médio de saturação de

água. Observa-se assim que a utilização do valor médio de porosidade no Caso 2 resulta num aumento pouco significativo do volume poroso ( $V_p$ ) quando comparado ao Caso 1, indicando uma distribuição pouco variável ao longo do reservatório. O aumento do espaço poroso no Caso 2 também resulta num aumento do valor de HCPV calculado. Para o Caso 3, a utilização de valores médios de saturação de água não afeta o volume poroso. O valor de HCPV calculado aumenta em relação ao Caso 1 de maneira similar ao Caso 2, indicando também uma distribuição pouco variável dos valores de saturação de água. Este comportamento observado nos Casos 2 e 3 corresponde com os baixos valores de CV na zona do reservatório obtidos na etapa de modelamento (Tabela 8).

A comparação dos valores obtidos dos classificadores de K-Means e GMM (Casos 7, 8 e 9) com os valores obtidos nos Casos 1, 2 e 3 mostra que a definição de valores de N/G afeta de maneira significativa os volumes finais obtidos. Atribuir a todas as células valores de 1 para N/G pode levar a grandes superestimações do conteúdo de hidrocarbonetos disponível no reservatório. Ao mesmo tempo, a comparação dos Casos 7, 8 e 9 com os casos obtidos de valores de corte para as propriedades (Casos 4, 5 e 6) indica que a definição de valores de corte pode levar a subestimações de volumes de hidrocarbonetos até para casos considerando um percentil de 50% como o Caso 4.

## 5. CONCLUSÕES

A combinação dos algoritmos de Krigagem com Deriva Externa (KDE) e Gaussian Random Function Simulation (GRFS) permite a modelagem de dados de poço para um modelo volumétrico tridimensional de maneira satisfatória. Embora o algoritmo de KDE evite transições bruscas entre valores devido à suavização dos resultados, o GRFS tende a honrar melhor a distribuição estatística dos dados de entrada. A limitação do GRFS de necessitar dados de entrada distribuídos de forma aproximadamente normal é uma limitação clara do método. É possível, no entanto, que transformações prévias à execução do algoritmo possam possibilitar seu uso para propriedades distribuições não normais.

Quanto ao upscaling dos dados, o método desenvolvido neste estudo mostrou bons resultados, honrando de maneira geral a distribuição original dos dados de entrada. Exceções são notadas para picos muito altos ou baixos na curva de distribuição dos valores, aonde o método tende a subestimar altos valores e sobrestimar baixos valores.

Quanta à etapa de processamento sísmico, o fluxo de trabalho utilizado passando por atributos de realce de estruturas e realce de descontinuidades permitiu delinear um bom número de descontinuidades e construir um modelo estrutural do reservatório que, em conjunto com as propriedades modeladas, fornece base para os cálculos de volume.

Na etapa de classificação, os algoritmos de K-Means e GMM mostram-se como efetivas técnicas para classificação de células no modelo. O método GMM em especial mostra-se capaz de classificar as células não só de acordo com suas informações litológicas (porosidade, densidade, raio gama), mas também de acordo com as propriedades dos fluídos em seu espaço poroso (saturação de água e resistividade).

A principal vantagem do GMM em relação ao K-Means, no entanto, é a possibilidade de realizar classificações não discretas atribuindo à cada célula um valor de probabilidade. Neste estudo, porém, esta capacidade adicional do GMM não mostrou-se muito relevante, tendo em vista que a maior parte das células foi classificada com probabilidades muito próximas de 1 para sua respectiva classe.

Nota-se, no entanto, que não necessariamente o comportamento observado pelos classificadores será sempre observado. Embora a técnica de Mapas Auto-Organizáveis (Self-Organizing Maps – SOM) tenha se mostrado como bastante efetiva como técnica de redução de dimensionalidade para classificação ao reduzir um modelo de milhões de células para um mapa de 58x58 pixels, é possível que diferentes resultados fossem observados, em especial para as probabilidades do método GMM, caso as classificações fossem realizadas para o modelo completo em seu espaço original.

## 6. REFERÊNCIAS BIBLIOGRÁFICAS

Anderson, P., and R. Newrick, 2008, Strange but true stories of synthetic seismograms: CSEG Recorder, 12, December, 51–56.

ANP. 2013. Boletim da Produção de Petróleo e Gás Natural. Agência Nacional do Petróleo, Gás Natural e Biocombustíveis, Superintendência de Desenvolvimento e Produção (SDP). 26p.

Bahorich, M. and Farmer, S. 1995. 3D Seismic Discontinuity for Faults and Stratigraphic Features: The Coherence Cube. The Leading Edge 14 (10)

Basir, H. M., Javaherian, A., & Yarak, M. T. 2013. Multi-attribute ant-tracking and neural network for fault detection: a case study of an Iranian oilfield. Journal of Geophysics and Engineering

Benabbou, A., Daly, C., Macé, L., Levannier, A., & Buchholz, C. 2015. An unstructured depositional grid for property modeling. In: Petroleum Geostatistics 2015.

Bentley, M., & Smith, S. 2008. Scenario-based reservoir modelling: the need for more determinism and less anchoring. Geological Society, London, Special Publications, 309(1), 145-159. doi:10.1144/sp309.11

Bjorlykke, K. 1989. Sedimentology and petroleum geology.

Brown, A.R. 1999. Interpretation of Three-Dimensional Seismic Data, 9, 528, fifth edition. Tulsa, Oklahoma: Investigations in Geophysics, Soc. of Exploration Geophysicists.

Bruhn C.H.L. 1998. Petroleum Geology of Rift and Passive Margin Turbidite Systems: Brazilian and Worldwide Examples. In: AAPG International Conference and Exhibition, Rio de Janeiro, Brazil. Part 2, Course 6.

Bruhn, C.; Gomes, J.; Lucchese Jr., C.; Johann, P. 2003. Campos Basin: Reservoir Characterization and Management – Historical Overview and Future Challenges. Offshore Technology Conference, Houston, Tx. OTC-15220.

Bruno, P. P. G., Cippitelli, G., & Rapolla, A. 1998. Seismic study of the Mesozoic carbonate basement around Mt. Somma–Vesuvius, Italy. *Journal of volcanology and Geothermal Research*

Caers, J., Park, K., & Scheidt, C. 2010. Modeling Uncertainty of Complex Earth Systems in Metric Space. *Handbook Of Geomathematics*

Caers, J. 2011. Modeling uncertainty in the earth sciences.

Chopra, S. & Marfurt, K. J. 2007. Seismic attributes for prospect identification and reservoir characterization.

Chahine, C., Truelove, L., & Volcan, M. H. 2014. Enhanced delineation of reservoir compartmentalization from advanced preand post-stack seismic attribute analysis.

Chen, L., Xiao, C., Li, X., Wang, Z., & Huo, S. 2018. A seismic fault recognition method based on ant colony optimization. *Journal of Applied Geophysics*, 152, 1-8.

Cobb, W. M., & Marek, F. J. 1998. Net pay determination for primary and waterflood depletion mechanisms. In SPE Annual Technical Conference and Exhibition. Society of Petroleum Engineers.

Cox, T., & Seitz, K. 2007. Ant tracking seismic volumes for automated fault interpretation. In CSPG CSEG Convention, Calgary, Alberta, Canada.

CSM E&P Solutions. 2012. Automated Data Conditioning – Ant Tracking Workflow.

Daly, C., & Caers, J. 2010. Multi-point geostatistics—an introductory overview. *First Break*, 28(9), 39-47.



Deutsch, C. V. & Journel, A. G. 1992. GSLIB Geostatistical Software Library and User's Guide Oxford University Press, New York

Deutsch, C. V. 1999. Reservoir modeling with publicly available software. Computers & Geosciences.

Dias, J.L.; Scarton, J.C.; Esteves, F.R.; Carminatti, M.; Guardado, L.R. 1990. Aspectos da Evolução Tectono-Sedimentar e a Ocorrência de Hidrocarbonetos na Bacia de Campos. In: Origem e Evolução de Bacias Sedimentares, Raja Gabaglia, G.P. and Milani, E.J., eds., Petrobras, Rio de Janeiro, Brasil.

Dongas, J. M. 2016. Development and characterization of a geostatic model for monitoring shallow CO<sub>2</sub> injection.

Elias V.L.G.; Steagall, D.E. 1996. The Impact of the Values of Cementation Factor and Saturation Exponent in the Calculation of Water Saturation for Macae Formation. SCA Conference Paper Number 9611

Ellis, Darwin V.; Singer, Julian M. 2008. Well Logging for Earth Scientists (Second ed.). Springer. p. 692. ISBN 1-4020-3738-4.

ESRI. 2019. How Kriging Works. Disponível em: <http://desktop.arcgis.com/en/arcmap/10.3/tools/3d-analyst-toolbox/how-kriging-works.htm>. Acesso em: 17/03/2019.

Fang, J., Zhou, F., & Tang, Z. 2017. Discrete fracture network modelling in a naturally fractured carbonate reservoir in the Jingbei oilfield, China. Energies, 10(2), 183.

Fletcher, M., Dornhaus, A., & Shin, M. C. 2011. Multiple ant tracking with global foreground maximization and variable target proposal distribution. In Applications of Computer Vision (WACV), 2011 IEEE Workshop on (pp. 570-576). IEEE.

Franz, E.P. 1987. Análise da Geologia de Reservatório dos Carbonatos da Formação Macaé do Campo de Enchova – Bacia de Campos, Brasil. Dissertação de Mestrado, Departamento de Geologia da Escola de Minas, Universidade Federal de Ouro Preto, Ouro Preto. 120p.

Figueiredo, A.M.F.; Mohriak, W.U. 1984. A Tectônica Salífera e as Acumulações de Petróleo da Bacia de Campos. In: SBG, Congresso Brasileiro de Geologia, 33, Anais, Rio de Janeiro, p.1380- 1394.

Guardado, L.R., Gamboa, L.A.P., Lucchesi, C.F. 1989. Petroleum Geology of the Campos Basin: A Model for Producing Atlantic Type Basin. In: Edwards, J.D. and Santogrossi, P.A., eds., Divergent/Passive Margin Basins. AAPG Memoir, 48, p.3-79.

Godfrey, R., & Bachrach, R. 2008. Seismically Guided Fracture Characterization.

Gonçalves M.L., Netto M.L. de A., Zullo, J.J. 1996. Um Sistema Neural Modular para Classificação de Imagens Utilizando Mapas de Kohonen. Anais VIII Simp. Bras. De Sensoriamento Remoto 6º Encontro Nacional de Inteligência Artificial, 1:845-849, Salvador, BA.

Hale, D. 2009. Structure-oriented smoothing and semblance. CWP report, 635, 261-270.

Hall, M., & Hall, M. 2013. Well-tie workflow. Agile. Disponível em:

<https://agilescientific.com/blog/2013/4/25/well-tie-workflow.html>. Acesso em: 20/10/2018.

Hampson, D. & Russell, B. 2004. AVO theory. Hampson-Russell Software Services Ltd, 22-26.

Hengl, T. 2009. A practical guide to geostatistical mapping. Amsterdam: Hengl.

Herrera, R. H., Fomel, S., & van der Baan, M. 2014. Automatic approaches for seismic to well tying.

Hunter, J.D., 2007. Matplotlib: A 2D graphics environment. Computing in science & engineering.

Krief, M., Garati, J., Stellingwerff, J. & Ventre, J. 1990. A petrophysical interpretation using the velocities of P- and S- waves (Full-wave sonic). The log analyst.

Kuroda, M. C., Vidal, A. C., Leite, E. P., & Drummond, R. D. 2012. Electrofacies characterization using self-organizing maps. Revista Brasileira de Geofísica.

Leite E.P., Filho C.R.S. 2010. Mapas Auto-Organizáveis aplicados ao mapeamento do potencial mineral na região de Serra Leste, Província Mineral de Carajás, Pará. Rev. Brasileira de Geofísica. 28(3):397-409.

Lloyd, S. 1982. Least squares quantization in PCM. IEEE transactions on information theory, 28(2), 129-137.

Matos M.C., Osório P.L.M., Johann P.R.S. 2004. Agrupamento de Mapas Auto Organizáveis de Kohonen Aplicado a Análise de Fácies Sísmicas. XV Brazilian Automation Congress, 1:1-6.

McKinney, W. 2010. Data structures for statistical computing in python. In Proceedings of the 9th Python in Science Conference.

Melani, L., Vidal, A. C., Filho, I. M., & Schuab, F. B. 2015. The impact of Archie's parameters in the calculation of water saturation for carbonate reservoir, Campos Basin, Brazil. In SEG Technical Program Expanded Abstracts 2015 (pp. 2984-2989). Society of Exploration Geophysicists.

Nelson, R.A. 2001. Geologic Analysis of Naturally Fractured Reservoirs. 2 nd Ed. Woburn, Massachusetts, USA. Gulf Professional Publishing. 332p.

Newrick, R. 2012. Well tie basics. Well tie perfection, 52, 104-107

Pedersen, S. I., Skov, T., Randen, T., & Sønneland, L. 2005. Automatic fault extraction using artificial ants. In Mathematical Methods and Modelling in Hydrocarbon Exploration and Production (pp. 107-116). Springer Berlin Heidelberg

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V. and Vanderplas, J., 2011. Scikit-learn: Machine learning in Python. Journal of machine learning research

Ponte J. P. P. 2019. Aplicação de métodos computacionais na análise de imagens referentes a dados geológicos. Dissertação de Mestrado. Universidade Estadual de Campinas.

- Pyrzcz, M. J., & Deutsch, C. V. 2014. Geostatistical reservoir modeling. Oxford university press.
- Oliphant, T.E., 2006. A guide to NumPy (Vol. 1, p. 85). Trelgol Publishing.
- Oliveira, M.L. 1997. Análise de Incertezas Envolvidas na Modelagem de Reservatório no Contexto Geoestatístico. Dissertação de Mestrado. Universidade Estadual de Campinas.
- Ralha, J.F.S. 2016. Mapeamento de Falhas e Fraturas por Reflexão Sísmica em um Campo Produtivo da Bacia de Campos. Trabalho de Conclusão de Curso. Universidade Estadual de Campinas.
- Randen, T., Monsen, E., Signer, C., Abrahamsen, A., Hansen, J. O., Sæter, T., & Schlaf, J. (2000). Three-dimensional texture attributes for seismic data analysis. In SEG Technical Program Expanded Abstracts 2000. Society of Exploration Geophysicists.
- Randen, T., Pedersen, S. I., & Sonneland, L. 2001. Automatic extraction of fault surfaces from three-dimensional seismic data. In Annual International Meeting, Society of Exploration Geophysicists
- Raykov, Y.P., Boukouvalas, A., Baig, F. and Little, M.A., 2016. What to do when k-means clustering fails: A simple yet principled alternative algorithm.
- Rijks, E. J. H., & Jauffred, J. C. E. M. 1991. Attribute extraction: An important application in any detailed 3-D interpretation study. The Leading Edge, 10(9), 11-19.
- Ringrose P. & Bentley M. 2014a. Introduction to Modeling. In: Reservoir Model Design. Springer, Dordrecht
- Ringrose, P., & Bentley, M. 2014b. Model Purpose. In: Reservoir Model Design, Springer, Dordrecht
- Robaina, L.E.S; Formoso, M.L.L.; Spadini, A.R. 1991. Carbonatos Reservatório da Formação Macaé, Bacia de Campos, RJ, Brasil. Parte I – Contribuição à Geoquímica dos Carbonatos. Geochim. Brasil.

Romary, T., Rivoirard, J., Deraisme, J., Quinones, C., & Freulon, X. 2012. Domainning by clustering multivariate geostatistical data. In Geostatistics Oslo 2012. Springer, Dordrecht.

Schlumberger. 2015. Petrel Seismic-to-Evaluation Software Documentation.

Silva, C. C., Marcolino, C. S., & Lima, F. D. 2005. Automatic fault extraction using ant tracking algorithm in the Marlim South Field, Campos Basin. In 9th International Congress of the Brazilian Geophysical Society.

Spadini, A.R. 1992. Processos Depositionais e Ciclicidade em Carbonatos Albianos de Plataforma Rasa da Bacia de Campos. Dissertação de Mestrado, Instituto de Geociências UFRJ

Spadini, A.R. 2008. Carbonate Reservoirs in Brazilian Sedimentary Basins. 19th World Petroleum Congress, Spain.

Stewart, R. R., Huddleston, P. D., & Kan, T. K. 1984. Seismic versus sonic velocities: A vertical seismic profiling study. *Geophysics*, 49(8), 1153-1168.

Stundner M. & Oberwinkler C. 2004. Self-Organizing Maps for Lithofacies Identification and Permeability Prediction. In: SPE Annual Technical Conference and Exhibition held in Houston, p.8.

Taner, M.T., Koehler, F., and Sheriff, R.E. 1979. Complex Seismic Trace Analysis. *Geophysics* 44 (6): 1041.

Trabanou, J.R.; Chabernaud, T.; Goswami, J.; Li, J.; Horkowitz, J.; Jacobsen, S.; Neville, T.; Seydoux, J. 2004. How Certain Are We About Reservoir Parameter Uncertainties? 45th Annual Logging Symposium SPWLA.

Tomaso, L.; Benac, P.; Sarturi, J.; González, G.; de Ribet, B. 2013. Seismic Fracture Characterization Workflow and Support for the Geological Model: Albian Carbonate Reservoir, Campos Basin, Brazil. 13th International Congress of the Brazillian Geophysical Society, Rio de Janeiro, Brazil.

Van Bommel, P. P., & Pepper, R. E. 2000. U.S. Patent No. 6,151,555. Washington, DC: U.S. Patent and Trademark Office.

VanderPlas, J., 2016. Python data science handbook: essential tools for working with data. O'Reilly Media, Inc.

Van Der Walt, S., Colbert, S. C., & Varoquaux, G. 2011. The NumPy array: a structure for efficient numerical computation. Computing in Science & Engineering

Vesanto J. & Alhoniemi E. 2000. Clustering of the Self-Organizing Map. IEEE Transactions on Neural Networks, 11:586-600

Wackernagel, H. 1995. Multivariate geostatistics: an introduction with applications.

White, R. E., & Simm, R. 2003. Tutorial: Good practice in well ties. First Break, 21(10).

Winter, W.R.; Jahnert, R.J.; França, A.B. 2007. Bacia de Campos. Boletim de Geociências da Petrobras, Rio de Janeiro

Zanão, R. 2008. Técnicas Geostatísticas Aplicadas na Modelagem de Saturação de Óleo. Dissertação de Mestrado. Universidade Estadual de Campinas.

Zeng, H., & Kerans, C. 2003. Seismic frequency control on carbonate seismic stratigraphy: A case study of the Kingdom Abo sequence, west Texas. AAPG bulletin, 87(2), 273-293.

Zhao, T., Jayaram, V., Roy, A., & Marfurt, K. J. 2015. A comparison of classification techniques for seismic facies recognition.